



المدرسة الوطنية للعلوم التطبيقية - بني ملال
ⵜⴰⵎⴰⵏⵜ ⵜⴰⵎⴰⵏⵉⵙⵜ ⵜⴰⵏⵓⵔⵉⵙⵜ ⵜⴰⵎⴰⵏⵉⵙⵜ
Ecole Nationale des Sciences Appliquées - Béni Mellal



Rapport de Maintien en Condition Opérationnelle

TRANSFORMATION DIGITALE INDUSTRIELLE (TDI)

Maintenance Prédictive des Moteurs Turbofan

Réalisé par :

EL Harkaoui Meriem

Najah Khaoula

Ouabbi Mohamed

Encadré par :

M. EL Alaoui Mohamed

Année universitaire : 2023/2024

Remerciements

Je tiens à exprimer mes sincères remerciements à **M. EL Alaoui Mohamed** pour son soutien précieux et ses conseils éclairés tout au long de ce travail. Sa disponibilité, son expertise et son engagement ont été des piliers essentiels à la réussite de ce projet. Je lui suis profondément reconnaissant pour ses encouragements constants et son accompagnement bienveillant tout au long de ce parcours.

Table des matières

Remerciements	i
Table des Matières	v
Liste des Figures	viii
Introduction Générale	1
Chapitre 1	3
1 Concepts Fondamentaux de la Maintenance et Contexte du Projet	3
1.1 Compréhension de la Maintenance : Concepts, Importance et Typologie	3
1.1.1 Définition de la Maintenance	3
1.1.2 Importance de la Maintenance	3
1.1.3 Types de Maintenance	4
1.2 Contexte du Projet et Données Utilisées	6
1.2.1 Contexte	6
1.2.2 Moteurs Turbo-fan (Moteur à Turbines)	6
1.2.3 Description des Ensembles de Données	8
Chapitre 2	11
2 Lois Statistiques et Analyse de Temps de Fonctionnement	11
2.1 Concepts Généraux de la Fiabilité	11
2.1.1 Définition	11
2.1.2 Fonction de défaillance $F(t)$ - Fonction de fiabilité $R(t)$	11
2.1.3 Taux de défaillance instantané	13
2.2 Lois de Fiabilité	13
2.2.1 Lois discrètes	14
2.2.2 Les lois continues	14
2.3 Analyse du Temps de Fonctionnement et Sélection des Lois de Distribution . . .	16
2.3.1 Analyse du Temps de Fonctionnement	17
2.3.2 Ajustement des Lois sur les Données	18

2.3.3	Validation de l'Ajustement	19
2.4	La Loi Log-Normale	22
2.4.1	Relations Mathématiques Associées	22
2.4.2	Estimation des Paramètres et Visualisation des Fonctions	23
2.4.3	Calcul de MTTF (Mean Time To Failure)	25
2.5	La Loi Gamma	30
2.5.1	Relations Mathématiques Associées	30
2.5.2	2. Estimation des Paramètres et Visualisation des Fonctions	31
2.5.3	3. Estimation de la Durée Restante (RUL) pour l'Ensemble de Test . . .	33
2.6	Comparaison des Résultats et Synthèse	34
2.6.1	Résultats	34
2.6.2	Conclusion	36
Chapitre 3		37
3	Prétraitement et Exploration des Données	37
3.1	Préparation des Données Brutes	37
3.1.1	Structure des Données et Définition des Colonnes	37
3.1.2	Vérification et Nettoyage des Données	38
3.2	Sélection des Caractéristiques	40
3.2.1	Importance de la Moyenne Roulante	40
3.2.2	Critères de Sélection des Caractéristiques	40
3.3	3. Conclusion : Sélection Finale des Caractéristiques	43
3.4	Analyse Exploratoire des Données (EDA)	43
3.4.1	Analyse de Corrélation	44
3.4.2	Visualisation des Comportements des Signaux des Capteurs	45
3.4.3	Observations sur les signaux des moteurs et des capteurs	49
3.4.4	Conclusion	49
Chapitre 4		51
4	Modélisation de la Dégradation Exponentielle pour la Prédiction de la RUL	51
4.1	Identification de l'Indicateur de Santé	51
4.1.1	Préparation des Données	51
4.1.2	Sélection des Caractéristiques	52
4.1.3	Réduction de Dimensionnalité avec PCA	52
4.1.4	Visualisation des Tendances des Moteurs	55
4.1.5	Détermination d'un Seuil de Défaillance	55
4.2	Modèle de l'Indicateur de Santé (Exponentiel)	56
4.2.1	Modélisation	56

4.2.2	Ajustement du Modèle pour Chaque Moteur	57
4.3	Prédiction de la Durée de Vie Restante (RUL)	58
4.3.1	Méthodologie	58
4.3.2	Résultats et Analyse des Performances	60
4.3.3	Analyse des résultats	61
4.3.4	Conclusion	62
Chapitre 5		63
5	Prédiction du RUL Basée sur l'Analyse de Similarités Multi-Facteurs	63
5.1	Analyse de Similarités Multi-Facteurs (ASMF)	64
5.1.1	Identification des Régimes de Fonctionnement	64
5.1.2	Sélection des Paramètres Prépondérants	64
5.1.3	Fusion des Données	64
5.1.4	Construction d'un Modèle de Régression Linéaire pour l'Indicateur de Santé	65
5.1.5	Lissage de l'Indicateur de Santé Final	66
5.1.6	Modélisation de l'Évolution de l'Indicateur de Santé	67
5.1.7	Estimation des Coefficients	67
5.1.8	Prédiction du RUL : Construction d'un modèle RUL basé sur la similarité	67
5.2	Résultats et Analyse des Performances	70
5.2.1	Comparaison entre les RUL prédit et réel	70
5.2.2	Métriques d'erreur	71
5.2.3	Analyse des résultats	71
5.3	Conclusion	71
Chapitre 6		73
6	Modèles Classiques pour la Prédiction et Classification de l'État des Moteurs	73
6.1	Modèles supervisés : Régression Linéaire, SVM et Random Forest	73
6.1.1	Préparation de données	73
6.1.2	Régression Linéaire	74
6.1.3	Support Vector Machine (SVM)	74
6.1.4	Modèle Random Forest	76
6.1.5	Résultats et Analyse	77
6.2	II. Approche de Classification pour la Prédiction de l'État des Moteurs	78
6.2.1	1. Préparation de données	78
6.2.2	2. Entraînement d'un modèle SVM pour la classification	79
6.2.3	3. Résultats et Analyse des Performances	80
Chapitre 7		83

7 Développement d'un Tableau de Bord interactif pour le Suivi et la Visualisation des États des Moteurs	83
7.1 Vue Globale : Synthèse des états des moteurs	84
7.2 Vue Moteur : Analyse individuelle	85
7.3 Conclusion	86
Conclusion Générale	87

Table des figures

1.1	Les Types de Maintenance	4
1.2	Moteur à turbines	7
1.3	Composants d'un turbo-fan	7
1.4	Captures d'écran des données	9
2.1	Fonction de défaillance $F(t)$	12
2.2	Les fonctions de fiabilité $R(t)$ et de défaillance $F(t)$	12
2.3	Distribution des temps de défaillance (failure time) par moteur	17
2.4	Les fonctions de densités (PDF) ajustées pour chaque distribution	18
2.5	Les résultats du test de Kolmogorov-Smirnov (KS)	20
2.6	Résultats du test χ^2	21
2.7	Résultats AIC et BIC pour chaque loi ajustée	22
2.8	Comparaison des données simulées et réelles	24
2.9	Densité de probabilité $f(t)$ - Log Normal	24
2.10	Fonction de défaillance $F(t)$ et de fiabilité $R(t)$ - Log Normal	25
2.11	Taux de défaillance $\lambda(t)$ - Log Normal	25
2.12	Évolution des erreurs en fonction de la fiabilité souhaitée	29
2.13	Évolution du R^2 en fonction de la fiabilité souhaitée	29
2.14	Comparaison des données simulées (par distribution Gamma) et réelles	31
2.15	Fonction de densité de probabilité $f(t)$ (pour la loi Gamma)	32
2.16	Fonction de défaillance $F(t)$ et de fiabilité $R(t)$ (pour la loi Gamma)	32
2.17	Taux de défaillance $\lambda(t)$ (pour la loi Gamma)	33
2.18	L'évolution des métriques d'erreur en fonction de la fiabilité choisie pour la distribution Gamma	33
2.19	Comparaison entre la durée de vie restante estimée et réelle (RUL) - loi Log-Normale	34
2.20	Évolution de la durée de vie restante estimée et réelle par moteur - loi Log-Normale	35
2.21	Comparaison entre la durée de vie restante estimée et réelle (RUL) - loi Gamma	35
2.22	Évolution de la durée de vie restante estimée et réelle par moteur - loi Gamma	35
3.1	Valeurs Manquantes, Unicité et Types de données	39

3.2	Aperçu des colonnes restantes	40
3.3	Scores de Monotonie par Colonne	41
3.4	Scores de Tendabilité par Colonne	42
3.5	Scores de Prognosabilité par Colonne	43
3.6	La matrice de corrélation entre les colonnes	44
3.7	Corrélations élevées (seuil ≥ 0.9)	44
3.8	Température à la sortie du compresseur basse pression (LPC)	45
3.9	Température à la sortie du compresseur haute pression (HPC)	45
3.10	Température à la sortie de la turbine basse pression (LPT)	45
3.11	Pression à la sortie du compresseur haute pression (HPC)	46
3.12	Vitesse physique du ventilateur	46
3.13	Vitesse physique du noyau	46
3.14	Pression statique à la sortie du compresseur haute pression (HPC)	47
3.15	Rapport du débit de carburant à Ps30	47
3.16	Vitesse corrigée du ventilateur	47
3.17	Rapport de dérivation	48
3.18	Enthalpie du prélèvement d'air	48
3.19	Flux d'air de refroidissement des turbines haute pression	48
3.20	Flux d'air de refroidissement des turbines basse pression	49
4.1	Composantes principales	53
4.2	PC1 et PC2 en fonction de la RUL	54
4.3	Évolution de l'indicateur de santé (PC1) par cycle	54
4.4	Indicateurs de santé pour plusieurs moteurs	55
4.5	Distribution de l'indicateur de santé (PC1) selon les niveaux de RUL	56
4.6	Les paramètres A, B, et σ pour chaque moteur	57
4.7	L'indicateur de santé observé et prédit pour un moteur donné (moteur 23)	58
4.8	Comparaison des Prédications de RUL pour Quelques Moteurs de Test	59
4.9	Comparaison entre l'Indicateur de Santé Réel et la Dégradation Prédite pour le Moteur 84	60
4.10	Comparaison entre la Durée de Vie Restante (RUL) Prédit et Réelle	60
4.11	Comparaison entre la Durée de Vie Restante (RUL) Prédit et Réelle pour Chaque Moteur	61
4.12	RUL Prédit et Réel pour un Moteur avec Plus de 200 Cycles	62
4.13	RUL Prédit et Réel pour un Moteur avec Moins de 30 Cycles	62
5.1	Indicateur de Santé Initial pour les moteurs 70 à 100	65
5.2	Indicateur de Santé Final pour les Unités 71 à 100	66
5.3	Indicateur de Santé Final et Points de Défaillance	66
5.4	Comparaison de l'Indicateur de Santé Réel et Ajusté pour différents moteurs	67

5.5	5 Modèles les Plus Similaires pour un moteur de test	69
5.6	Évolution de R^2 et RMSE en fonction de K	70
5.7	Comparaison entre la durée de vie restante (RUL) Prédit et réelle	70
5.8	Comparaison entre la durée de vie restante (RUL) Prédit et réelle pour Chaque Moteur	71
6.1	Support Vector Machine (SVM)	75
6.2	Illustration de l'algorithme Random Forest	76
6.3	Comparaison entre la durée de vie restante (RUL) Prédit par SVM et réelle . . .	77
6.4	Comparaison entre la durée de vie restante (RUL) Prédit par SVM et réelle pour Chaque Moteur	78
6.5	Matrice de confusion	79
6.6	Matrice de confusion	81
7.1	Première page - Vue Globale	84
7.2	Deuxième page - Vue Moteur	85

Introduction Générale

Dans un monde industriel en constante évolution, la maintenance des équipements critiques est devenue essentielle pour assurer la sécurité, la disponibilité et la rentabilité des opérations. Les moteurs turbo-fan, utilisés dans les systèmes de propulsion aéronautique, illustrent parfaitement cette réalité. Ces équipements sophistiqués, soumis à des contraintes mécaniques et environnementales intenses, nécessitent une gestion rigoureuse de leur cycle de vie afin d'éviter les pannes coûteuses et les arrêts imprévus.

La maintenance industrielle a connu une transformation majeure avec l'émergence de l'industrie 4.0 et des technologies modernes telles que l'intelligence artificielle (IA) et le machine learning. Ces outils permettent de passer d'une maintenance réactive, où l'intervention a lieu après la panne, à une maintenance prédictive, où les défaillances sont anticipées grâce à des modèles basés sur l'analyse des données. Cette transition offre aux entreprises un avantage stratégique en améliorant la disponibilité des équipements, en réduisant les coûts d'exploitation, et en augmentant la fiabilité globale des systèmes.

Ce projet s'inscrit dans cette dynamique et vise à développer une solution de maintenance prédictive pour les moteurs turbo-fan, en utilisant le jeu de données CMAPSS (Commercial Modular Aero-Propulsion System Simulation) fourni par la NASA. Ce jeu de données riche en informations réelles offre une base solide pour analyser les performances des moteurs et prédire leur durée de vie restante (Remaining Useful Life - RUL). L'objectif principal est d'exploiter les lois statistiques et les modèles d'apprentissage automatique pour anticiper les pannes et optimiser les stratégies de maintenance.

Pour assurer une compréhension complète et méthodique, ce document est organisé de manière à guider le lecteur à travers les différentes étapes du projet. Après avoir exploré les types de maintenance et présenté les données utilisées, nous détaillerons les analyses statistiques et les lois sous-jacentes. Par la suite, des modèles de machine learning seront développés pour prédire le RUL, avec une évaluation minutieuse de leur performance. Enfin, les résultats obtenus seront illustrés à l'aide de visualisations claires, accompagnées de recommandations pratiques pour intégrer ces solutions dans des stratégies de maintenance robustes et efficaces. Une attention particulière sera également accordée aux contrats de maintenance, en détaillant le Plan de Continuité d'Activité (PCA) et le Plan de Reprise d'Activité (PRA) en vue de garantir une gestion optimale et une continuité des opérations en cas d'imprévus.

En conclusion, ce projet vise à mettre en avant la valeur ajoutée des technologies modernes

pour relever les défis de la maintenance prédictive. Il propose une approche structurée et des outils concrets pour anticiper les défaillances, optimiser les opérations industrielles et contribuer à la durabilité et à la performance des équipements critiques.

Chapitre 1

Concepts Fondamentaux de la Maintenance et Contexte du Projet

1.1 Compréhension de la Maintenance : Concepts, Importance et Typologie

1.1.1 Définition de la Maintenance

Selon la norme AFNOR (Association Française de Normalisation) NF-X 60 000, la maintenance est « l'ensemble des activités ayant pour objectif de maintenir ou rétablir un bien dans un état spécifié de fonctionnement pour établir une fonction requise. » La maintenance rassemble donc l'ensemble des actions visant à maintenir ou à restaurer un équipement dans un état opérationnel, afin qu'il puisse remplir la fonction pour laquelle il a été conçu. Cela inclut une série d'opérations techniques destinées à prévenir, détecter et réparer les pannes des équipements de production. Ces opérations peuvent concerner des machines, des systèmes, des infrastructures ou des installations complexes. La maintenance est donc essentielle pour garantir la performance, la fiabilité et la sécurité des équipements industriels. Selon l'ISO 55000, la maintenance comprend à la fois des actions de surveillance et des interventions telles que la réparation, l'ajustement, le nettoyage et le remplacement de pièces.

1.1.2 Importance de la Maintenance

Impact sur la disponibilité des équipements : La maintenance assure que les équipements sont disponibles au moment où ils sont requis, ce qui favorise une production plus efficace. Une maintenance préventive soigneusement planifiée aide à identifier et à résoudre les problèmes avant qu'ils ne provoquent des pannes inattendues, diminuant ainsi les interruptions et garantissant un fonctionnement optimal des machines.

Réduction des coûts liés aux pannes et aux arrêts de production : Les coûts associés à une panne d'équipement peuvent être très élevés, non seulement en ce qui concerne les réparations, mais aussi en termes de perte de production et de temps d'arrêt. La maintenance préventive et prédictive s'avère particulièrement efficace pour réduire ces coûts en détectant les problèmes avant qu'ils ne se transforment en défaillances majeures. D'après une étude de l'American Society of Mechanical Engineers (ASME), les coûts d'une panne imprévue peuvent atteindre jusqu'à huit fois ceux de la maintenance préventive. En anticipant et en planifiant les interventions, les entreprises peuvent ainsi éviter des dépenses considérables et maintenir un niveau de production stable.

Amélioration de la sécurité et de la qualité des produits : La maintenance joue un rôle crucial dans la sécurité des équipements et des travailleurs, en minimisant les risques liés à des pannes inattendues. En veillant à ce que les équipements opèrent selon les spécifications, elle assure également la qualité des produits fabriqués. Par conséquent, la maintenance contribue à maintenir des normes élevées de sécurité et de qualité tout au long du processus de production.

1.1.3 Types de Maintenance

La norme NF-X 60 000 différencie deux grandes familles : la maintenance corrective et la maintenance préventive.




FIGURE 1.1 – Les Types de Maintenance

Maintenance Corrective

Définition AFNOR de la maintenance corrective : « Maintenance exécutée après détection d'une panne et destinée à remettre un bien dans un état dans lequel il peut accomplir une fonction requise ». La maintenance corrective correspond à une opération engagée suite à une panne, un sinistre ou un aléa. Elle a pour objectif de remettre en fonctionnement les machines par un dépannage, une réparation ou le remplacement de pièces défectueuses. Elle se divise en deux sous-catégories :

Palliative : La maintenance palliative correspond au dépannage. Elle consiste à remettre provisoirement une machine ou un outil en état, dans l'attente de sa réparation. La maintenance palliative permet d'éviter l'arrêt total de production, on parle alors de reprise de production en mode « dégradé ». Exemple : Lorsqu'un tuyau d'arrosage est percé, une maintenance palliative consiste à réparer provisoirement la fuite avec du ruban adhésif.

Curative : La maintenance curative répare les causes et conséquences de la panne. Contrairement à la maintenance palliative, il s'agit d'une action en profondeur qui agit sur le long terme, souvent en remplaçant la pièce défectueuse par une neuve. L'équipement reprend alors une production normale. Exemple : L'action de maintenance curative sera de changer le tuyau d'arrosage percé par un nouveau tuyau.

Maintenance Préventive

Définition AFNOR de la maintenance préventive : « Maintenance exécutée à des intervalles prédéterminés ou selon des critères prescrits et destinée à réduire la probabilité de défaillance ou la dégradation du fonctionnement d'un bien ». La maintenance préventive est donc, comme son nom l'indique, de la prévention par l'entretien régulier d'une machine ou d'un bien. Elle consiste à faire des contrôles selon des normes établies et/ou conformément aux instructions du fabricant, mais également en fonction de l'expérience humaine et des historiques d'interventions réalisés sur le bien.

La maintenance préventive a pour but de :

- garantir la disponibilité du bien,
- augmenter sa durée de vie,
- diminuer la probabilité des pannes et donc d'actions de maintenance corrective,
- contrôler les consommations d'énergie ou de pièces détachées en contribuant à la maîtrise des stocks.

On distingue plusieurs types de maintenance préventive :

Systématique : La maintenance préventive systématique est effectuée selon un échancier, en fonction du temps ou du nombre d'unités d'usage, mais sans contrôle préalable du bien. La fréquence des interventions est établie à compter de la mise en fonctionnement du bien ou à la suite d'une révision partielle ou complète de celui-ci. Exemple : Le changement d'huile sur une machine peut être défini au bout d'un certain nombre de semaines d'utilisation sans contrôle spécifique préalable.

Conditionnelle : La maintenance préventive conditionnelle est basée sur une surveillance du bien en fonction d'un type d'évènement prédéfini (auto-diagnostique, information de capteurs...). Elle fait intervenir des informations recueillies en temps réel, au moyen de techniques

comme la tribologie ou la thermographie par infra-rouge, avec pour objectif d'intervenir au moment où le bien a franchi le seuil d'usure ou de dégradation fixé préalablement.

Prévisionnelle : La maintenance préventive prévisionnelle (parfois appelée prédictive) est d'après la définition AFNOR « une maintenance conditionnelle exécutée en suivant les prévisions extrapolées de l'analyse et de l'évaluation de paramètres significatifs de la dégradation du bien ». Elle consiste à anticiper les besoins de la maintenance en permettant de prévenir les pannes ou les défaillances. C'est la maintenance 4.0, avec une surveillance en continu des évolutions de certains paramètres.

1.2 Contexte du Projet et Données Utilisées

1.2.1 Contexte

Les données utilisées sont des données de fonctionnement de turbines fournies par la NASA en 2008 lors de la première conférence internationale Prognostics and Health Management (PHM08). Bien que publiées il y a plus d'une décennie, le dataset CMAPSS de la NASA, simulant la dégradation des moteurs turbo-fan, reste à la fois populaire et pertinent. À titre d'exemple, plus de 90 nouvelles publications de recherche ont vu le jour en 2020. Dans le cadre de notre projet, nous exploitons ce dataset pour développer et valider des modèles innovants capables de prédire la Durée de Vie Résiduelle (RUL - Remaining Useful Life) des moteurs turbo-fan, conformément aux objectifs définis : identifier les lois statistiques régissant l'apparition des pannes et anticiper les défaillances futures.

1.2.2 Moteurs Turbo-fan (Moteur à Turbines)

Qu'est-ce qu'un moteur à turbines ?

Un moteur turbo-fan est un type de moteur à réaction largement utilisé dans les avions commerciaux et militaires. Il appartient à la famille des moteurs à turbine à gaz et se distingue par le fait qu'il utilise un ventilateur pour accélérer l'air dans son mécanisme. Ce ventilateur, situé à l'avant du moteur, permet non seulement d'augmenter la poussée du moteur mais aussi de le rendre plus économe en carburant par rapport aux autres types de moteurs à réaction.



FIGURE 1.2 – Moteur à turbines

Composants d'un moteur à turbines

Les composants essentiels d'un moteur turbo-fan comprennent le ventilateur, le compresseur, la chambre de combustion, la turbine et la postcombustion. Chaque pièce joue un rôle essentiel dans le fonctionnement du moteur, et la conception globale est optimisée pour obtenir une efficacité et des performances maximales :




FIGURE 1.3 – Composants d'un turbo-fan

- **Ventilateur** : Situé à l'avant, le ventilateur initie le fonctionnement du moteur en aspirant l'air. Il propulse également une grande quantité d'air autour de l'extérieur du cœur du moteur, contribuant ainsi à la majeure partie de la poussée des moteurs à taux de dilution élevé.
- **Le compresseur** : Il augmente la pression de l'air reçu du ventilateur avant qu'il ne pénètre dans la chambre de combustion. Le compresseur est constitué de plusieurs étages d'aubes rotatives et joue un rôle crucial dans l'efficacité du moteur. Le compresseur d'un moteur turbo-fan peut être subdivisé en sections basse pression et haute pression.
- **Chambre de combustion** : C'est là que l'air comprimé se mélange au carburant et s'enflamme, créant ainsi des gaz à haute pression et à grande vitesse.
- **Turbine** : Entraînée par les gaz en expansion de la chambre de combustion, la turbine génère de l'énergie pour entraîner le ventilateur et le compresseur.

- **Postcombustion** : Composant optionnel qui permet d’augmenter encore la poussée en injectant et en allumant du carburant supplémentaire après la section de la turbine. Il est principalement utilisé dans les avions militaires pour améliorer les performances.

Fonctionnement du moteur turbo-fan

Le moteur turbo-fan fonctionne en aspirant une grande quantité d’air à l’aide d’un ventilateur situé à l’avant, qui dirige une partie de cet air dans le cœur du moteur et une autre partie autour, générant une poussée importante. L’air entrant dans le cœur est comprimé par un compresseur, divisé en sections basse et haute pression, pour augmenter son efficacité avant d’atteindre la chambre de combustion. Dans cette dernière, l’air comprimé est mélangé au carburant et enflammé, produisant des gaz chauds à haute pression. Ces gaz traversent ensuite une turbine, qui utilise leur énergie pour entraîner le ventilateur et le compresseur. Enfin, certains moteurs disposent d’une postcombustion optionnelle pour injecter et allumer du carburant supplémentaire, augmentant la poussée, notamment pour les besoins des avions militaires.

Pour une démonstration visuelle approfondie du fonctionnement d’un moteur turbo-fan, je vous recommande de regarder la vidéo suivante : [Fonctionnement du moteur turbo-fan]. Cette vidéo fournit une explication claire et illustrée qui complète les informations de ce rapport.

1.2.3 Description des Ensembles de Données

Les ensembles de données sont constitués de plusieurs séries temporelles multi-variées. Chaque ensemble est divisé en deux sous-ensembles : un ensemble d’entraînement et un ensemble de test. Chaque série temporelle provient d’un moteur différent, ce qui signifie que les données peuvent être considérées comme provenant d’une flotte de moteurs du même type.

Au début de chaque série temporelle, le moteur fonctionne normalement, et un défaut se développe progressivement jusqu’à une défaillance totale. Cette défaillance est atteinte dans l’ensemble d’entraînement, alors que dans l’ensemble de test, la série s’arrête avant que la défaillance ne survienne. L’objectif principal de cette étude est de prédire la durée de vie restante (RUL - Remaining Useful Life) des moteurs pour les données de test, exprimée en nombre de cycles d’opérations restants avant défaillance.

Les ensembles de données prennent en compte trois paramètres opérationnels qui influencent de manière significative les performances du moteur. Ces paramètres sont inclus dans les données, mais les mesures des capteurs sont affectées par un bruit de capteur, ajoutant une complexité supplémentaire à l’analyse. Chaque moteur démarre avec des degrés différents d’usure initiale et de variation de fabrication, considérés comme normaux et non comme des conditions de panne.

Structure des Données

Les données sont fournies sous forme de fichiers texte compressés (ZIP) contenant 26 colonnes, avec des valeurs numériques séparées par des espaces. Chaque ligne représente une capture des données lors d'un cycle opérationnel, tandis que chaque colonne correspond à une variable spécifique. Voici les colonnes principales :

- Colonne 1 : Numéro d'unité (identifiant du moteur)
- Colonne 2 : Temps en cycles
- Colonne 3 : Réglage opérationnel 1
- Colonne 4 : Réglage opérationnel 2
- Colonne 5 : Réglage opérationnel 3
- Colonnes 6 à 26 : Mesures des capteurs (de 1 à 26)

engine	time	op_setting_1	op_setting_2	op_setting_3	sm_1	sm_2	sm_3	sm_4	sm_5	...	sm_13	sm_14	sm_15	sm_16	sm_17	sm_18	sm_19	sm_20	sm_21
1	1	-0.0007	-0.0004	100.0	518.67	641.82	1589.79	1400.60	14.62	...	2388.02	8138.62	8.4195	0.03	392	2388	100.0	39.06	23.4190
1	2	0.0019	-0.0003	100.0	518.67	642.15	1591.82	1403.14	14.62	...	2388.07	8131.49	8.4318	0.03	392	2388	100.0	39.00	23.4236
1	3	-0.0043	0.0003	100.0	518.67	642.35	1587.99	1404.20	14.62	...	2388.03	8133.23	8.4178	0.03	390	2388	100.0	38.95	23.3442
1	4	0.0007	0.0000	100.0	518.67	642.35	1582.79	1401.87	14.62	...	2388.08	8133.83	8.3682	0.03	392	2388	100.0	38.88	23.3739
1	5	-0.0019	-0.0002	100.0	518.67	642.37	1582.85	1406.22	14.62	...	2388.04	8133.80	8.4294	0.03	393	2388	100.0	38.90	23.4044
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
100	196	-0.0004	-0.0003	100.0	518.67	643.40	1597.98	1428.63	14.62	...	2388.26	8137.60	8.4956	0.03	397	2388	100.0	38.40	22.9735
100	197	-0.0016	-0.0005	100.0	518.67	643.54	1604.50	1433.58	14.62	...	2388.22	8136.50	8.5139	0.03	395	2388	100.0	38.30	22.9594
100	198	0.0004	0.0000	100.0	518.67	643.42	1602.46	1428.18	14.62	...	2388.24	8141.05	8.5646	0.03	396	2388	100.0	38.44	22.9333
100	199	-0.0011	0.0003	100.0	518.67	643.23	1605.26	1426.53	14.62	...	2388.23	8139.29	8.5389	0.03	395	2388	100.0	38.29	23.0640
100	200	-0.0032	-0.0005	100.0	518.67	643.85	1600.38	1432.14	14.62	...	2388.26	8137.33	8.5036	0.03	396	2388	100.0	38.37	23.0522

FIGURE 1.4 – Captures d'écran des données

Détails des Ensembles de Données

Les ensembles de données sont divisés en quatre configurations (FD001 à FD004) qui varient en termes de conditions opérationnelles et de modes de panne :

- **FD001 :**
 - Trajectoires d'entraînement : 100
 - Trajectoires de test : 100
 - Conditions : Une seule (Niveau de la mer)
 - Modes de panne : Un (Dégradation du compresseur haute pression - HPC)
- **FD002 :**
 - Trajectoires d'entraînement : 260
 - Trajectoires de test : 259
 - Conditions : Six
 - Modes de panne : Un (Dégradation du HPC)
- **FD003 :**
 - Trajectoires d'entraînement : 100
 - Trajectoires de test : 100
 - Conditions : Une seule (Niveau de la mer)

- Modes de panne : Deux (Dégradation du HPC, Dégradation de l'hélice)
- **FD004** :
 - Trajectoires d'entraînement : 248
 - Trajectoires de test : 249
 - Conditions : Six
 - Modes de panne : Deux (Dégradation du HPC, Dégradation de l'hélice)

Dans le cadre de notre projet, nous avons utilisé uniquement le premier ensemble de données, FD001.

Chapitre 2

Lois Statistiques et Analyse de Temps de Fonctionnement

La fiabilité est une discipline essentielle pour analyser et gérer la maintenance des systèmes complexes. Elle permet d'évaluer la probabilité de bon fonctionnement d'un système sur une période donnée, tout en prévoyant les défaillances possibles. Ce chapitre propose une exploration approfondie des concepts fondamentaux de la fiabilité et des lois statistiques couramment utilisées pour modéliser les temps de fonctionnement.

Dans le cadre de notre projet, ces lois sont appliquées et ajustées aux données du dataset CMAPSS afin d'obtenir des indicateurs pertinents de performance et de durabilité.

2.1 Concepts Généraux de la Fiabilité

2.1.1 Définition

La fiabilité représente la probabilité qu'un produit accomplisse sa fonction requise sans défaillance dans des conditions d'utilisation spécifiques pendant une durée déterminée. Selon la norme NF X50-500, elle est définie comme une « caractéristique d'un bien exprimée par la probabilité qu'il accomplisse une fonction requise dans des conditions données pendant un temps donné. »

2.1.2 Fonction de défaillance $F(t)$ - Fonction de fiabilité $R(t)$

Soit T une variable aléatoire représentant le temps de bon fonctionnement d'un équipement.

— On appelle fonction de défaillance la fonction F définie pour tout $t \geq 0$.

$$F(t) = P(T \leq t)$$

Le nombre $F(t)$ représente la probabilité qu'un dispositif choisi au hasard ait une défaillance avant l'instant t .

- On distingue également la fonction de densité de défaillance $f(t)$, qui décrit la densité de probabilité de défaillance à l'instant t , c'est-à-dire la probabilité qu'un appareil tombe en panne à un instant donné, par unité de temps.

La fonction de répartition $F(t)$ et la fonction de densité $f(t)$ sont liées par la relation suivante :

$$F(t) = \int_0^t f(x)dx$$

Cela signifie que la fonction de défaillance $F(t)$ est l'intégrale de la fonction de densité $f(t)$ sur l'intervalle $[0, t]$, représentant la probabilité cumulative de défaillance avant l'instant t .




FIGURE 2.1 – Fonction de défaillance $F(t)$

Cette fonction nous amène naturellement à une fonction associée : la fonction de fiabilité R définie pour tout $t \geq 0$ par :

$$R(t) = 1 - F(t)$$

Le nombre $R(t)$ représente la probabilité qu'un dispositif choisi au hasard dans la population n'ait pas de défaillance avant l'instant t .




FIGURE 2.2 – Les fonctions de fiabilité $R(t)$ et de défaillance $F(t)$

Enfin, le taux d'avarie moyen, c'est-à-dire la probabilité de défaillance dans un intervalle de temps $[t, t + \Delta t]$ est donné par :

$$\frac{R(t) - R(t + \Delta t)}{R(t)} \times \frac{1}{\Delta t}$$

2.1.3 Taux de défaillance instantané

C'est la probabilité ($0 \leq R \leq 1$) qu'un produit accomplisse de manière satisfaisante une fonction requise, sous des conditions données et pendant une période de temps donnée. L'écriture mathématique du taux de défaillance à l'instant t , noté $\lambda(t)$, défini sur R est la suivante :

$$\lambda(t) = \lim_{\Delta t \rightarrow 0} \left(\frac{1}{\Delta t} \cdot \frac{R(t) - R(t + \Delta t)}{R(t)} \right)$$

Physiquement, le terme $\lambda(t)\Delta t$ mesure la probabilité qu'une défaillance d'un dispositif se produise dans l'intervalle de temps $[t, t + \Delta t]$, sachant que ce dispositif a bien fonctionné jusqu'à l'instant t , où $R(t)$ est la fonction de fiabilité de ce matériel.

$$\begin{aligned} \lambda(t) &= - \frac{dR(t)}{dt} \cdot \frac{1}{R(t)} \\ &= \frac{dF(t)}{dt} \cdot \frac{1}{R(t)} \\ &= \frac{f(t)}{R(t)} \end{aligned}$$

2.2 Lois de Fiabilité

Il est toujours possible d'associer à une variable aléatoire une probabilité et définir ainsi une loi de probabilité. Lorsque le nombre d'épreuves augmente indéfiniment, les fréquences

observées pour le phénomène étudié tendent vers les probabilités et les distributions observées vers les distributions de probabilité ou lois de probabilité. Une loi de probabilité est un modèle représentant "au mieux", une distribution de fréquences d'une variable aléatoire.

On distingue deux types de lois :

- Lois discrètes
- Lois continues

2.2.1 Lois discrètes

Une loi est dite discrète si elle prend ses valeurs dans N , c'est-à-dire des valeurs entières, comme par exemple celle qui compte le nombre de pannes. Parmi les lois discrètes, on peut citer :

- Loi Uniforme
- Loi de Bernoulli
- Loi Binomiale
- Loi Binomiale négative
- Loi Géométrique
- Loi Hypergéométrique
- Loi de Poisson

Cependant, dans notre cas, nous allons nous concentrer sur les lois continues, qui sont plus adaptées pour modéliser le temps de fonctionnement d'un moteur jusqu'à sa défaillance.

2.2.2 Les lois continues

Dans le cadre de l'étude de la fiabilité, les lois continues sont couramment utilisées pour modéliser le temps de fonctionnement jusqu'à la défaillance d'un système. Voici quelques-unes des lois continues les plus utilisées dans l'analyse de fiabilité :

- La loi exponentielle
- La loi Gamma
- Loi Inverse Gamma
- La loi Bêta
- La Loi normale
- La loi Log normale
- La loi de Weibull

a) La loi exponentielle

La fonction de densité de probabilité (PDF) de la loi exponentielle est donnée par :

$$f(t; \lambda) = \lambda e^{-\lambda t}, \quad t \geq 0, \quad \lambda > 0$$

où $\lambda > 0$ est le paramètre de taux.

b) La loi Gamma

La fonction de densité de probabilité de la loi Gamma est :

$$f(t; \alpha; \beta) = \frac{t^{\alpha-1} e^{-t/\beta}}{\beta^\alpha \Gamma(\alpha)}, \quad t \geq 0$$

avec :

- α : Paramètre de forme
- β : Paramètre d'échelle
- $\Gamma(\alpha)$: Fonction Gamma, qui est une généralisation de la factorielle.

c) Loi Inverse Gamma

La fonction de densité de probabilité de la loi Inverse Gamma est :

$$f(t; \alpha; \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} t^{-(\alpha+1)} e^{-\frac{\beta}{t}}, \quad t > 0, \quad \alpha > 0, \quad \beta > 0$$

avec :

- $\alpha > 0$: paramètre de forme
- $\beta > 0$: paramètre d'échelle

d) La loi Bêta

La fonction de densité de probabilité de la loi Bêta est :

$$f(t; \alpha; \beta) = \frac{t^{\alpha-1} (1-t)^{\beta-1}}{B(\alpha, \beta)}, \quad 0 \leq t \leq 1 \quad \alpha > 0, \quad \beta > 0$$

avec :

- α et β : Paramètres de forme
- $B(\alpha, \beta)$: Fonction Beta, qui est une généralisation de la factorielle pour des valeurs continues.

e) Loi Normale (ou Loi Gaussienne)

La fonction de densité de probabilité de la loi Normale est :

$$f(t; \mu; \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(t-\mu)^2}{2\sigma^2}}, \quad -\infty < t < \infty, \quad \sigma > 0$$

avec :

- μ : Moyenne
- σ : Écart-type

f) Loi Log-Normale

La fonction de densité de probabilité de la loi Log-Normale est :

$$f(t; \mu; \sigma) = \frac{1}{t\sigma\sqrt{2\pi}} e^{-\frac{(\ln t - \mu)^2}{2\sigma^2}}, \quad t > 0, \quad \sigma > 0$$

avec :

- μ : Moyenne du logarithme
- σ : Écart-type du logarithme

g) Loi de Weibull

La fonction de densité de probabilité de la loi Weibull est :

$$f(t; \alpha; \beta) = \frac{\alpha}{\beta} \left(\frac{t}{\beta}\right)^{\alpha-1} e^{-(t/\beta)^\alpha}, \quad t \geq 0, \quad \alpha > 0, \quad \beta > 0$$

avec :

- α : Paramètre de forme
- β : Paramètre d'échelle

2.3 Analyse du Temps de Fonctionnement et Sélection des Loïs de Distribution

Dans cette section, nous allons réaliser une analyse approfondie des temps de fonctionnement des moteurs turbo-fan afin de choisir la loi de distribution la plus adaptée. L'objectif est d'identifier la loi de distribution qui reflète le mieux ces phénomènes de défaillance, et de modéliser avec précision le comportement des défaillances des moteurs.

2.3.1 Analyse du Temps de Fonctionnement

a) Préparation des Données

Dans cette étape, nous nettoyons les données (éliminant les valeurs manquantes ainsi que les doublons). Nous nous concentrons ensuite sur les temps de fonctionnement des moteurs turbo-fan, que nous calculons en déterminant le nombre maximal de cycles effectués avant chaque défaillance.

```
failure_time = data_FD001.groupby('engine')['time'].max()
```

b) La Répartition des Temps de Défaillance




FIGURE 2.3 – Distribution des temps de défaillance (failure time) par moteur

D'après la distribution des temps de défaillance, on constate une asymétrie marquée avec une concentration des valeurs entre 150 et 200 cycles et une queue allongée, indiquant des comportements typiques de phénomènes de défaillance. En conséquence, les lois candidates qui semblent les plus adaptées pour modéliser ces données sont :

- Log-Normale
- Gamma
- Weibull
- Beta
- Normale

Ces lois seront testées pour identifier celle qui modélise le mieux les données des temps de fonctionnement des moteurs turbo-fan.

2.3.2 Ajustement des Loïs sur les Données

Pour cette étape, nous estimons les paramètres des différentes lois de distribution candidates en utilisant des méthodes d'ajustement statistique. Les paramètres sont ajustés pour chaque loi en fonction des données de temps de fonctionnement, dans le but de réduire l'écart entre les données observées et les distributions théoriques.

Voici un extrait de code utilisé pour ajuster les paramètres des lois.

```
from scipy.stats import weibull_min, norm, lognorm, gamma, beta

# Define the distributions you want to fit
distributions = {
    "Beta": beta,
    "Gamma": gamma,
    "Normal": norm,
    "Log-Normal": lognorm,
    "Weibull": weibull_min
}

# Store the results of fitting the distributions
fitted_params = {}

# Fit each distribution to the data and store the parameters
for name, dist in distributions.items():
    params = dist.fit(failure_time) # Fit the distribution to the data
    fitted_params[name] = params # Store the fitted parameters
```

Après l'ajustement des différentes lois de distribution aux données des temps de défaillance, nous comparons leurs fonctions de densité (PDF) à la distribution observée des données. Ce graphique superpose l'histogramme des temps de défaillance aux courbes des densités ajustées pour chaque loi candidate, permettant d'évaluer visuellement laquelle correspond le mieux aux données.




FIGURE 2.4 – Les fonctions de densités (PDF) ajustées pour chaque distribution

D'après ce graphe, on peut constater que, comme mentionné précédemment, ces lois sont des

candidates plausibles pour modéliser les données, notamment la Log-Normale, Gamma, Bêta (avec Gamma et Bêta apparaissant confondues sur le graphique), et Weibull. Cependant, pour déterminer avec précision la loi la plus adaptée, nous appliquerons plusieurs tests statistiques pour valider cette analyse.

2.3.3 Validation de l'Ajustement

Dans cette étape, nous allons appliquer des tests statistiques pour évaluer quantitativement l'adéquation des lois ajustées aux données observées et identifier la loi qui offre le meilleur compromis entre précision et complexité.

a) Test de Kolmogorov-Smirnov (KS)

Le test de Kolmogorov-Smirnov est défini comme un test statistique non paramétrique qui quantifie la différence entre la fonction de distribution empirique d'un échantillon et la fonction de distribution cumulative d'une distribution de référence, ou les fonctions de distribution empiriques de deux échantillons.

En termes plus simples, le test de Kolmogorov-Smirnov aide à comprendre si deux ensembles de données proviennent de la même distribution. Le test calcule la distance maximale K entre les fonctions de distribution cumulative (FDC) de deux échantillons ou d'un échantillon et d'une distribution de référence.

$$K = \sup |F(x) - F_0(x)|$$

où $F(x)$ sont les fonctions de distribution cumulées empiriques des deux échantillons. Pour un échantillon et une distribution de référence, on remplacerait F par la fonction de distribution cumulative de la référence.

- Plus la valeur K est petite, plus il est probable que les deux ensembles suivent la même distribution.
- Ce test repose sur une hypothèse nulle : les données suivent la distribution de référence.
(Rejet de H_0 si K est trop grand)

Les résultats du test de Kolmogorov-Smirnov (KS) pour chaque distribution candidate sont présentés dans le tableau ci-dessous. Ces résultats incluent la statistique KS, qui mesure la distance maximale entre les fonctions de distribution, ainsi que la p-value, qui indique si l'hypothèse nulle peut être acceptée ou rejetée.

D'après ces résultats, les lois log-normale, gamma, et beta se distinguent comme les meilleures candidates pour modéliser les données de temps de défaillance.

	KS	p_value
Log-Normal	0.071910	0.652432
Gamma	0.078931	0.535430
Beta	0.079032	0.533805
Weibull	0.094090	0.318623
Normal	0.138333	0.039376

FIGURE 2.5 – Les résultats du test de Kolmogorov-Smirnov (KS)

b) Le test du Chi-deux (ou test de χ^2)

Le test du χ^2 d'ajustement, ou d'adéquation, compare globalement la distribution observée dans un échantillon statistique à une distribution théorique. Le test du χ^2 est basé sur la somme des carrés des écarts normalisés entre les fréquences observées et les fréquences attendues. La formule est la suivante :

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

où :

- O_i est la fréquence observée dans la i -ème classe (ou intervalle),
- E_i est la fréquence attendue dans la i -ème classe, calculée selon la loi théorique,
- k est le nombre total de classes dans l'histogramme.

Une fois que le χ^2 a été calculé, il est comparé à une distribution de χ^2 avec $k - 1$ degrés de liberté. La valeur p est la probabilité d'obtenir une valeur de χ^2 aussi extrême, ou plus extrême, que celle calculée à partir de l'échantillon. Elle est déterminée à l'aide de la fonction de distribution cumulée de χ^2 .

Le test du χ^2 d'ajustement a été appliqué pour chaque loi de distribution candidate (Weibull, Log-Normal, Gamma, Beta, Normal) afin de vérifier si l'ajustement des données observées suit une distribution théorique.

Même si les lois Log-Normale, Beta, et Gamma se distinguent comme les meilleures candidates pour modéliser les données de temps de défaillance.

	χ^2	p_value
Log-Normal	7.036038	0.633367
Beta	7.658930	0.568849
Gamma	7.717748	0.562822
Weibull	10.394762	0.319482
Normal	29.389340	0.000557

FIGURE 2.6 – Résultats du test χ^2

c) AIC (Akaike Information Criterion) et BIC (Bayesian Information Criterion)

Les critères AIC et BIC sont utilisés pour évaluer la qualité d'un modèle statistique tout en tenant compte de sa complexité. Ces deux critères permettent de comparer plusieurs modèles et de choisir celui qui offre le meilleur compromis entre ajustement aux données et simplicité (complexité du modèle).

L'AIC est défini par la formule suivante :

$$\text{AIC} = 2k - 2\ln(\hat{L})$$

où :

- k est le nombre de paramètres estimés dans le modèle,
- $\hat{L}$ est la valeur de la fonction de vraisemblance maximisée du modèle.

Le modèle avec l'AIC le plus bas est considéré comme le meilleur parmi les candidats, car il pénalise les modèles plus complexes (avec plus de paramètres).

Le BIC est similaire à l'AIC, mais il pénalise davantage les modèles complexes, surtout pour des tailles d'échantillons plus grandes. La formule est la suivante :

$$\text{BIC} = \ln(n)k - 2\ln(\hat{L})$$

où :

- n est le nombre d'observations (taille de l'échantillon),
- k est le nombre de paramètres estimés dans le modèle,
- $\hat{L}$ est la fonction de vraisemblance maximisée du modèle.

En appliquant ces critères à nos données de temps de défaillance, nous avons obtenu les valeurs suivantes pour chaque distribution :

	Beta	Gamma	Normal	Log-Normal	Weibull
AIC	1039.859333	1037.857388	1053.995642	1037.872591	1039.032455
BIC	1050.280014	1045.672899	1059.205982	1045.688101	1046.847966

FIGURE 2.7 – Résultats AIC et BIC pour chaque loi ajustée

d) Conclusion

Les tests de Kolmogorov-Smirnov, χ^2 , AIC et BIC ont révélé que les distributions Log-Normale, Gamma et Beta sont les meilleures options pour modéliser les données de temps de défaillance. Parmi celles-ci, les distributions Log-Normale et Gamma se sont particulièrement démarquées par leur adéquation aux données, surtout lors des évaluations AIC et BIC.

En conclusion, nous avons choisi de continuer notre étude avec les distributions Log-Normale.

2.4 La Loi Log-Normale

La loi Log-Normale est une distribution de probabilité utilisée pour modéliser des données strictement positives, où la variable d'intérêt suit une distribution normale après une transformation logarithmique. En d'autres termes, si une variable aléatoire X suit une loi Log-Normale, alors $Y = \ln(X)$ suit une loi Normale.

2.4.1 Relations Mathématiques Associées

Pour une loi Log-Normale avec les paramètres μ (moyenne logarithmique) et σ (écart-type logarithmique) :

Fonction de densité de probabilité (PDF)

Elle représente la fréquence des défaillances à différents moments. Un pic dans $f(t)$ indique le moment où les défaillances sont les plus probables.

$$f(t) = \frac{1}{t\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln t - \mu)^2}{2\sigma^2}\right), \quad t > 0 \quad (2.1)$$

Fonction de distribution cumulative $F(t)$ (ou fonction de défaillance)

La fonction cumulative donne la probabilité qu'une défaillance se produise avant un temps t .

$$F(t) = \Phi\left(\frac{\ln t - \mu}{\sigma}\right) \quad (2.2)$$

- Φ est la fonction de répartition de la loi normale standard.
- μ et σ sont les paramètres de la distribution log-normale.

Fonction de fiabilité $R(t)$ (ou fonction de survie)

Elle représente la probabilité qu'une unité (moteur) fonctionne correctement sans défaillance jusqu'à un instant t .

$$R(t) = 1 - F(t) = 1 - \Phi\left(\frac{\ln t - \mu}{\sigma}\right) \quad (2.3)$$

Fonction de taux de défaillance instantané $\lambda(t)$ (ou taux de défaillance)

Elle quantifie la probabilité qu'une défaillance se produise dans un intervalle infinitésimal autour de t , étant donné que l'unité a survécu jusqu'à t .

$$\lambda(t) = \frac{f(t)}{R(t)} \quad (2.4)$$

Fonction de risque cumulatif $H(t)$

La fonction de risque cumulatif est utile pour comprendre l'évolution du risque de défaillance au fil du temps.

$$H(x) = -\ln(R(x)) = -\ln\left(1 - \Phi\left(\frac{\ln(x) - \mu}{\sigma}\right)\right), \quad x > 0$$

- $H(t)$ est utile pour comprendre l'évolution du risque de défaillance sur le temps.
- Une croissance rapide de $H(t)$ signale un système en phase de vieillissement critique.

2.4.2 Estimation des Paramètres et Visualisation des Fonctions

Après avoir ajusté les données à une distribution log-normale, les paramètres ajustés jouent un rôle essentiel dans la compréhension de la forme de la loi et dans l'évaluation de la pertinence de l'ajustement. Ces paramètres incluent :

- Moyenne logarithmique $\mu = 5.3012$
- Écart-type logarithmique $\sigma = 0.2132$

Ces valeurs représentent respectivement la moyenne et la dispersion logarithmiques des données de défaillance observées.

Pour évaluer l'adéquation de l'ajustement à la loi Log-Normale, nous avons généré un ensemble d'échantillons simulés à partir des paramètres ajustés (μ et σ). Ces échantillons simulés représentent les temps de défaillance théoriques selon la distribution Log-Normale.




FIGURE 2.8 – Comparaison des données simulées et réelles

Pour mieux comprendre le comportement de la distribution log-normale ajustée, les principales fonctions mathématiques associées sont représentées ci-dessous.




FIGURE 2.9 – Densité de probabilité $f(t)$ - Log Normal




FIGURE 2.10 – Fonction de défaillance $F(t)$ et de fiabilité $R(t)$ - Log Normal




FIGURE 2.11 – Taux de défaillance $\lambda(t)$ - Log Normal

2.4.3 Calcul de MTTF (Mean Time To Failure)

Le MTTF (Mean Time To Failure) représente la durée de vie moyenne avant défaillance, il correspond à l'espérance mathématique du temps avant une défaillance. Dans le cas de la loi log-normale, il est donné par la formule :

$$\text{MTTF} = e^{\mu + \frac{\sigma^2}{2}}$$

Où :

- μ est la moyenne logarithmique des données
- σ est l'écart-type logarithmique des données

Résultat calculé : Le calcul du MTTF, basé sur les paramètres ajustés de la distribution log-normale ($\mu = 5.3012, \sigma = 0.2132$), montre que la durée de vie moyenne des moteurs avant défaillance est estimée à 205 cycles.

4. Prédiction de la Durée de Vie Restante (RUL) Basée sur la Loi Log-Normale

a) Estimation du temps avant défaillance à une fiabilité donnée

Pour une fiabilité souhaitée R , la durée avant défaillance est obtenue en inversant la fonction de répartition $F(t)$. La relation mathématique est donnée par :

$$F(t) = 1 - R(t) \quad (2.5)$$

Ainsi, pour une fiabilité donnée R , la durée avant défaillance estimée est :

$$t = F^{-1}(1 - R) \quad (2.6)$$

Exemple : Dans notre cas, pour une fiabilité de 95% ($R = 0.95$), nous obtenons :

$$t = 145 \text{ cycles} \quad (2.7)$$

Le temps estimé avant défaillance est de 145 cycles.

b) Estimation Conditionnelle après un Nombre de Cycles Réalisés

L'estimation conditionnelle de la durée de vie restante après un certain nombre de cycles réalisés repose sur la probabilité conditionnelle. En d'autres termes, une fois que le moteur a fonctionné pendant N cycles, nous pouvons estimer combien de cycles supplémentaires il peut encore effectuer pour atteindre une fiabilité R donnée.

Probabilité Conditionnelle de Survie : La probabilité conditionnelle que le moteur continue à fonctionner pendant un temps supplémentaire t après avoir déjà fonctionné pendant t_0 cycles est donnée par :

$$P(T > t_0 + t \mid T > t_0) = \frac{R(t_0 + t)}{R(t_0)} \quad (2.8)$$

L'objectif est de déterminer la durée restante, c'est-à-dire combien de cycles supplémentaires le moteur peut fonctionner pour une fiabilité R donnée. Pour cela, nous fixons une fiabilité R , puis nous résolvons l'équation suivante :

$$R = \frac{R(t_0 + t_{sup})}{R(t_0)}$$

$$1 - F(t_0 + t_{sup}) = R \cdot R(t_0)$$

$$t_{sup} = F^{-1}(1 - R \cdot R(t_0)) - t_0$$

Exemple : Considérons un moteur ayant réalisé $t_0 = 50$ cycles, et souhaitons estimer les cycles supplémentaires pour une fiabilité de 90% ($R = 0.90$) :

$$t_{sup} = 104 \text{ cycles supplémentaires} \quad (2.9)$$

c) Estimation de la Durée Restante (RUL) pour l'Ensemble de Test

Ici, nous allons appliquer la méthode d'estimation conditionnelle décrite précédemment pour évaluer la durée de vie restante des équipements dans un ensemble de tests, en tenant compte des cycles déjà effectués et de la fiabilité souhaitée.

Choix de la Fiabilité : Le choix de la fiabilité R est un élément essentiel dans cette estimation. En général, une fiabilité élevée est souhaitable, mais dans la pratique, nous optons pour un seuil de fiabilité qui correspond aux contraintes et aux exigences de maintenance. Pour illustrer, nous commencerons avec une fiabilité de 90% ($R = 0.90$).

Estimation de la Durée Restante :

1. Préparation du jeu de données de test et calcul du nombre maximum de cycles réalisés.

```
# DataFrame des cycles réalisés par moteur
test_cycles_realises = test_FD001.groupby('engine')['time'].max()
```

2. Calcul de la durée restante estimée, sachant que la fiabilité est de 90%.

```
# Calculer la durée de vie restante pour chaque moteur
duree_vie_restante = test_cycles_realises.apply(
    lambda x: estimer_duree_supplementaire(x, fiabilite_souhaitee=0.9)
)

# Afficher les résultats sous forme de DataFrame
resultats = pd.DataFrame({
    'engine': test_cycles_realises.index,
    'cycles_realises': test_cycles_realises.values,
    'duree_vie_restante_estime': duree_vie_restante.values,
    'duree_vie_restante_reel': rul_true.RUL
})
```

	engine	cycles_realises	duree_vie_restante_estime	duree_vie_restante_reel
0	1	31	159	112
1	2	49	141	98
2	3	126	64	69
3	4	106	84	82
4	5	98	92	91

Évaluation du Modèle

Pour évaluer la qualité de l'estimation de la durée restante, nous utiliserons trois critères de performance courants :

- **RMSE (Root Mean Square Error)** : La racine carrée de l'erreur quadratique moyenne est une mesure de l'écart moyen entre les valeurs estimées et les valeurs réelles.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_{\text{réel},i} - y_{\text{prédit},i})^2}$$

- **MAE (Mean Absolute Error)** : L'erreur absolue moyenne mesure la différence absolue moyenne entre les valeurs estimées et les valeurs réelles.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_{\text{réel},i} - y_{\text{prédit},i}|$$

- **R² (Coefficient de Détermination)** : Ce coefficient mesure la proportion de la variance des données expliquée par le modèle d'estimation.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_{\text{réel},i} - y_{\text{prédit},i})^2}{\sum_{i=1}^n (y_{\text{réel},i} - \bar{y}_{\text{réel}})^2}$$

Nous allons calculer ces métriques de performance pour différentes valeurs de la fiabilité R , comme illustré dans les graphiques ci-dessous.




FIGURE 2.12 – Évolution des erreurs en fonction de la fiabilité souhaitée




FIGURE 2.13 – Évolution du R^2 en fonction de la fiabilité souhaitée

Pour une fiabilité de 57%, on constate des erreurs minimales.

2.5 La Loi Gamma

Nous allons suivre la même approche que pour la loi log-normale, mais cette fois-ci avec la loi gamma. Nous procéderons à l'ajustement des données, à l'estimation des paramètres, et à l'évaluation des métriques de performance pour les prédictions basées sur cette nouvelle distribution.

Une distribution Gamma ou loi Gamma est un type de loi de probabilité des variables aléatoires réelles positives. Une distribution Gamma est caractérisée par deux paramètres :

- α (paramètre de forme) : détermine la forme de la fonction de densité.
- β (paramètre d'échelle) : contrôle l'étirement ou la compression de la distribution.

Ces deux paramètres influencent la représentation graphique de sa fonction de densité.

2.5.1 Relations Mathématiques Associées

Fonction de densité de probabilité : La fonction de densité de probabilité de la loi Gamma est donnée par :

$$f(t; \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} t^{\alpha-1} e^{-\beta t}, \quad t > 0,$$

où :

- $\alpha > 0$ est le paramètre de forme,
- $\beta > 0$ est le paramètre d'échelle,
- $\Gamma(\alpha)$ est la fonction Gamma définie par $\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt$.

Fonction de défaillance : La fonction de défaillance est donnée par :

$$F(t; \alpha, \beta) = \frac{\gamma(\alpha, \beta t)}{\Gamma(\alpha)}$$

où $\int_0^t$ représente l'intégrale de la fonction Gamma incomplète.

Fonction de fiabilité : La fonction de fiabilité, qui représente la probabilité de survie jusqu'à un instant t , est donnée par :

$$R(t; \alpha, \beta) = 1 - F(t) = \frac{\Gamma(\alpha, \beta t)}{\Gamma(\alpha)},$$

Fonction de taux de défaillance instantané : Le taux de défaillance instantané est donné par :

$$R(t; \alpha, \beta) = 1 - F(t) = \frac{\Gamma(\alpha, \beta t)}{\Gamma(\alpha)},$$

2.5.2 2. Estimation des Paramètres et Visualisation des Fonctions

Après avoir ajusté les données à une distribution Gamma, les paramètres ajustés jouent un rôle essentiel dans la compréhension de la forme de la loi et dans l'évaluation de la pertinence de l'ajustement. Ces paramètres incluent :

- Paramètre de forme (α) : $\alpha = 4.11$
- Paramètre d'échelle (β) : $\beta = 0.04$

Nous générons les temps de défaillance théoriques selon la distribution Gamma avec ces paramètres ajustés.




FIGURE 2.14 – Comparaison des données simulées (par distribution Gamma) et réelles

Les principales fonctions mathématiques associées sont représentées ci-dessous.




FIGURE 2.15 – Fonction de densité de probabilité $f(t)$ (pour la loi Gamma)




FIGURE 2.16 – Fonction de défaillance $F(t)$ et de fiabilité $R(t)$ (pour la loi Gamma)




FIGURE 2.17 – Taux de défaillance $\lambda(t)$ (pour la loi Gamma)

2.5.3 3. Estimation de la Durée Restante (RUL) pour l'Ensemble de Test

Nous allons suivre la même approche ici pour estimer la durée de vie restante (RUL) des équipements en utilisant la distribution Gamma. Comme pour la loi Log-Normale, nous appliquerons la méthode d'estimation conditionnelle pour évaluer la durée de vie restante en fonction des cycles déjà effectués et de la fiabilité souhaitée. Nous choisirons également un seuil de fiabilité approprié pour cette estimation, et nous évaluerons la performance du modèle en utilisant des métriques telles que l'Erreur Quadratique Moyenne (RMSE), l'Erreur Absolue Moyenne (MAE) et le Coefficient de Détermination (R^2).

Les graphiques suivants montreront l'évolution de ces métriques en fonction de la fiabilité choisie pour la distribution Gamma.




FIGURE 2.18 – L'évolution des métriques d'erreur en fonction de la fiabilité choisie pour la distribution Gamma

Pour une fiabilité de 57 %, on constate des erreurs minimales.

2.6 Comparaison des Résultats et Synthèse

2.6.1 Résultats

Dans cette section, nous comparons les résultats des estimations de la durée de vie restante (RUL) obtenues à partir des deux lois de probabilité : Log-Normale et Gamma, en utilisant une fiabilité fixée à 57%. Cette analyse vise uniquement à comparer les performances des deux lois dans le contexte des temps de fonctionnement, sans tenir compte des valeurs des capteurs. Il est important de noter que cette fiabilité est relativement faible, et normalement, une fiabilité plus élevée serait souhaitée pour assurer des prévisions plus fiables. Cependant, cette étude sert avant tout de référence pour les modélisations futures en Machine Learning (ML), qui intégreront les données de capteurs et permettront de construire des modèles plus précis.

Les résultats des deux lois sont comparés à travers les graphiques suivants, qui montrent l'évolution du RUL réel par rapport au RUL prédit par chaque loi. De plus, un tableau récapitule les erreurs de chaque modèle, incluant les valeurs de l'Erreur Absolue Moyenne (MAE), de l'Erreur Quadratique Moyenne (RMSE) et du Coefficient de Détermination (R^2).

a) L'évolution du RUL réel par rapport au RUL prédit

Loi Log-Normale :




FIGURE 2.19 – Comparaison entre la durée de vie restante estimée et réelle (RUL) - loi Log-Normale




FIGURE 2.20 – Évolution de la durée de vie restante estimée et réelle par moteur - loi Log-Normale

Loi Gamma :




FIGURE 2.21 – Comparaison entre la durée de vie restante estimée et réelle (RUL) - loi Gamma




FIGURE 2.22 – Évolution de la durée de vie restante estimée et réelle par moteur - loi Gamma

b) Comparaison des métriques d'erreur

Loi	Erreur Absolue Moyenne (MAE)	Erreur Quadratique Moyenne (RMSE)	Coefficient de Détermination (R^2)
Log-Normale	28.51	36.13	0.24
Gamma	28.78	35.69	0.26

TABLE 2.1 – Métriques d'erreur pour les lois Gamma et Log-Normale à une fiabilité de 0.57

2.6.2 Conclusion

Cette étude se concentre sur l'analyse des temps de fonctionnement en utilisant les lois Log-Normale et Gamma pour estimer la durée de vie restante (RUL). Bien que les résultats fournissent une première base de comparaison entre les deux lois, cette étude ne prend en compte que les temps de fonctionnement et ne tient pas compte des valeurs des capteurs.

En conclusion, cette analyse sert de référence pour les futures modélisations en Machine Learning, qui intégreront les données de capteurs et permettront d'améliorer les prévisions. Dans les chapitres suivants, nous approfondirons l'utilisation des technologies d'analyse de données et de Machine Learning pour la construction de modèles de maintenance plus avancés. Ces modèles permettront une prédiction plus précise de la durée de vie restante en prenant en compte des variables supplémentaires issues des capteurs.

Chapitre 3

Prétraitement et Exploration des Données

L'analyse prédictive fondée sur le machine learning requiert des données de haute qualité et des caractéristiques significatives pour assurer des résultats pertinents. Ce chapitre se concentre sur la préparation des données provenant des capteurs et leur exploration en vue de modéliser la durée de vie restante (RUL). Nous commencerons par les étapes essentielles de nettoyage et de prétraitement des données pour éliminer les incohérences, normaliser les variables et garantir leur adéquation pour l'analyse. Ensuite, nous procéderons à une sélection rigoureuse des caractéristiques, en nous basant sur des critères tels que la monotonie, la tendabilité et la prognosabilité, afin d'identifier les variables les plus informatives. Enfin, une analyse exploratoire des données (EDA) sera réalisée pour visualiser les relations entre les caractéristiques sélectionnées et le RUL, tout en identifiant les schémas et tendances utiles. Ce processus servira de fondation pour le développement des modèles de machine learning, qui seront abordés dans les chapitres suivants. L'objectif ultime de ce chapitre est de s'assurer que les données brutes sont transformées en une forme exploitable et que les caractéristiques retenues maximisent les performances des modèles prédictifs.

3.1 Préparation des Données Brutes

3.1.1 Structure des Données et Définition des Colonnes

Voici la structure des colonnes principales :

- **Colonnes principales et paramètres d'opération :**
 - `engine` : Identifiant unique du moteur.
 - `time` : Cycle opérationnel (nombre de cycles depuis le début de la simulation).
 - `op_setting_1`, `op_setting_2`, `op_setting_3` : Paramètres d'opération simulés.
- **Mesures des capteurs :**

— `sm_1` à `sm_21` : Mesures issues des capteurs.

Voici une description des capteurs :

- `sm_1` : Température à l'entrée du ventilateur.
- `sm_2` : Température à la sortie du compresseur basse pression (LPC).
- `sm_3` : Température à la sortie du compresseur haute pression (HPC).
- `sm_4` : Température à la sortie de la turbine basse pression (LPT).
- `sm_5` : Pression à l'entrée du ventilateur.
- `sm_6` : Pression dans le conduit de dérivation.
- `sm_7` : Pression à la sortie du compresseur haute pression (HPC).
- `sm_8` : Vitesse physique du ventilateur.
- `sm_9` : Vitesse physique du noyau.
- `sm_10` : Rapport de pression du moteur (P_{50}/P_2).
- `sm_11` : Pression statique à la sortie du compresseur haute pression (HPC).
- `sm_12` : Ratio du débit de carburant par rapport à Ps_{30} .
- `sm_13` : Vitesse corrigée du ventilateur.
- `sm_14` : Vitesse corrigée du noyau.
- `sm_15` : Ratio de dérivation.
- `sm_16` : Ratio carburant-air dans le brûleur.
- `sm_17` : Enthalpie du prélèvement d'air.
- `sm_18` : Vitesse requise du ventilateur.
- `sm_19` : Vitesse de conversion requise du ventilateur.
- `sm_20` : Flux d'air de refroidissement des turbines haute pression.
- `sm_21` : Flux d'air de refroidissement des turbines basse pression.

3.1.2 Vérification et Nettoyage des Données

Avant d'utiliser les données pour l'analyse ou l'entraînement des modèles, il est crucial d'évaluer leur qualité. Cela inclut la vérification des valeurs manquantes, des colonnes constantes et des anomalies potentielles.

Le tableau récapitulatif ci-dessous résume les vérifications effectuées :

	missing value	number unique value	dtype
engine	0	100	int64
time	0	362	int64
op_setting_1	0	158	float64
op_setting_2	0	13	float64
op_setting_3	0	1	float64
sm_1	0	1	float64
sm_2	0	310	float64
sm_3	0	3012	float64
sm_4	0	4051	float64
sm_5	0	1	float64
sm_6	0	2	float64
sm_7	0	513	float64
sm_8	0	53	float64
sm_9	0	6403	float64
sm_10	0	1	float64
sm_11	0	159	float64
sm_12	0	427	float64
sm_13	0	56	float64
sm_14	0	6078	float64
sm_15	0	1918	float64
sm_16	0	1	float64
sm_17	0	13	int64
sm_18	0	1	int64
sm_19	0	1	float64
sm_20	0	120	float64

FIGURE 3.1 – Valeurs Manquantes, Unicité et Types de données

Constantes : Les colonnes suivantes ont des valeurs constantes et ne contribuent pas à l'analyse :

— `op_setting_3`, `sm_1`, `sm_5`, `sm_10`, `sm_16`, `sm_18`, `sm_19` : Ces colonnes seront supprimées.

Après nettoyage, les données sont prêtes pour les prochaines étapes. Voici un aperçu des colonnes restantes :

engine	time	op_setting_1	op_setting_2	sm_2	sm_3	sm_4	sm_6	sm_7	sm_8	sm_9	sm_11	sm_12	sm_13	sm_14	sm_15	sm_17	sm_20	sm_21	
0	1	1	-0.0007	-0.0004	641.82	1589.70	1400.60	21.61	554.36	2388.06	9046.19	47.47	521.66	2388.02	8138.62	8.4195	392	39.06	23.4190
1	1	2	0.0019	-0.0003	642.15	1591.82	1403.14	21.61	553.75	2388.04	9044.07	47.49	522.28	2388.07	8131.49	8.4318	392	39.00	23.4236
2	1	3	-0.0043	0.0003	642.35	1587.99	1404.20	21.61	554.26	2388.08	9052.94	47.27	522.42	2388.03	8133.23	8.4178	390	38.95	23.3442
3	1	4	0.0007	0.0000	642.35	1582.79	1401.87	21.61	554.45	2388.11	9049.48	47.13	522.86	2388.08	8133.83	8.3682	392	38.88	23.3739
4	1	5	-0.0019	-0.0002	642.37	1582.85	1406.22	21.61	554.00	2388.06	9055.15	47.28	522.19	2388.04	8133.80	8.4294	393	38.90	23.4044
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	

FIGURE 3.2 – Aperçu des colonnes restantes

3.2 Sélection des Caractéristiques

La sélection des caractéristiques est une étape essentielle pour identifier les variables les plus pertinentes dans la prédiction de la durée de vie restante (Remaining Useful Life, RUL). Cette démarche repose sur l'analyse des données par le biais de trois critères principaux : la monotonie, la tendabilité (trendability) et la pronosticabilité (prognosability). Avant cela, nous introduisons la méthode de la moyenne roulante pour lisser les fluctuations aléatoires dans les données.

3.2.1 Importance de la Moyenne Roulante

La moyenne roulante (ou glissante) est une technique de prétraitement des données qui permet de lisser les variations aléatoires dans une série temporelle tout en conservant les tendances sous-jacentes. Elle est définie par :

$$MA(t) = \frac{1}{n} \sum_{i=t-n+1}^t x_i$$

où :

- $MA(t)$ est la moyenne roulante au temps t ,
- n est la fenêtre de la moyenne roulante,
- x_i représente les valeurs de la série temporelle.

Importance :

- **Réduction du bruit :** En éliminant les variations aléatoires, la moyenne roulante aide à mieux visualiser les tendances générales des données.
- **Stabilisation des caractéristiques :** Elle permet d'identifier des relations cohérentes et fiables entre les variables et le temps.

3.2.2 Critères de Sélection des Caractéristiques

a) Monotonie

La monotonie mesure dans quelle mesure une caractéristique suit une évolution régulière (croissante ou décroissante) au fil du temps. Elle est définie par :

$$\text{Monotonicity}(x) = \frac{1}{m} \sum_{i=1}^{n-1} \left| \frac{\text{nombres différences positives} - \text{nombre de différences négatives}}{n - 1} \right|$$

Où :

- m : nombre d'unités,
- n : nombre total de points de données.

Une forte monotonie indique que la caractéristique suit une tendance constante et peut être utile pour prédire la défaillance d'un système.

Résultats de Monotonie :

(Avant de calculer la monotonie, nous avons utilisé la moyenne glissante pour lisser les données et réduire le bruit.)




FIGURE 3.3 – Scores de Monotonie par Colonne

Les colonnes `sm_6`, `sm_17`, et `sm_3` présentent une faible monotonie, ce qui indique qu'elles ne suivent pas une tendance claire (croissante ou décroissante) et pourraient être moins utiles pour la modélisation prédictive. Ces colonnes peuvent être éliminées ou examinées de manière approfondie.

b) Tendance (Trendability)

La tendabilité mesure la capacité d'une caractéristique à suivre une tendance significative avec le temps. Elle est définie par la corrélation entre la caractéristique et le temps :

$$\text{Trendability}(x) = \frac{1}{M} \sum_{j=1}^M |\text{corr}(x_j, t_j)|$$

Où :

— $\text{corr}(x_j, t_j)$: corrélation entre la caractéristique et le temps.

Une forte tendabilité indique que la caractéristique est capable de capturer une tendance prévisible.

Résultats de Tendabilité :




FIGURE 3.4 – Scores de Tendabilité par Colonne

La colonne **sm_6** a un score de tendabilité nul, ce qui justifie son élimination.

c) Pronosticabilité

La pronosticabilité mesure la variance d'un prédicteur en fin de vie (End of Life, EoL) pour l'ensemble des unités. Formellement, la pronosticabilité d'un prédicteur (caractéristique) est définie par :

$$\text{pronosticabilité} = \exp \left(- \frac{\text{std}_j(x_j(N_j))}{|\text{mean}_j(x_j(1)) - x_j(N_j)|} \right)$$

où :

— $\text{std}_j(x_j(N_j))$: écart-type des dernières valeurs d'une caractéristique pour l'unité j,

— $|\text{mean}_j(x_j(1)) - x_j(N_j)|$: moyenne des différences entre les premières et dernières valeurs.

Une forte pronosticabilité indique une meilleure capacité à prévoir les défaillances futures.

Résultats de Pronosticabilité :

Ici, nous avons calculé la pronosticabilité pour les 50 derniers cycles avant la défaillance.




FIGURE 3.5 – Scores de Prognosabilité par Colonne

Les colonnes `sm_6`, `sm_9`, et `sm_14` présentent une pronosticabilité faible, ce qui reflète une variance réduite des valeurs à la fin de vie (EoL). Cela réduit leur utilité pour prévoir les comportements futurs des équipements surveillés.

3.3 3. Conclusion : Sélection Finale des Caractéristiques

Colonnes éliminées :

— `sm_6` en raison de ses faibles scores dans les trois critères (monotonie, tendabilité, pronosticabilité).

3.4 Analyse Exploratoire des Données (EDA)

L'objectif principal de cette étape est de mieux comprendre les relations entre les caractéristiques sélectionnées et la durée de vie restante (RUL) des moteurs. Cela inclut l'analyse de corrélation et la visualisation des comportements des capteurs.

3.4.1 Analyse de Corrélation

L'analyse de corrélation permet d'identifier les relations linéaires ou non linéaires entre les capteurs sélectionnés et la durée de vie restante (RUL). Nous avons calculé la matrice de corrélation pour toutes les caractéristiques.




FIGURE 3.6 – La matrice de corrélation entre les colonnes

Le graphique ci-dessous montre les caractéristiques avec une corrélation élevée (≥ 0.9).




FIGURE 3.7 – Corrélations élevées (seuil ≥ 0.9)

Les colonnes sm_9 et sm_14 sont fortement corrélées avec une valeur de corrélation de 0.96. Afin de réduire la redondance dans les données, nous avons décidé d'éliminer la colonne sm_14, qui est redondante par rapport à sm_9.

3.4.2 Visualisation des Comportements des Signaux des Capteurs

Pour approfondir la compréhension de la relation entre les capteurs sélectionnés et la durée de vie restante (RUL), nous avons analysé l'évolution des signaux des capteurs lors des derniers cycles avant la défaillance. Une moyenne glissante a été utilisée pour lisser les fluctuations et révéler les tendances sous-jacentes. Pour illustrer cette analyse, nous avons choisi d'afficher les signaux pour 10 moteurs sélectionnés aléatoirement, offrant ainsi une vue représentative des variations observées.




FIGURE 3.8 – Température à la sortie du compresseur basse pression (LPC)




FIGURE 3.9 – Température à la sortie du compresseur haute pression (HPC)




FIGURE 3.10 – Température à la sortie de la turbine basse pression (LPT)




FIGURE 3.11 – Pression à la sortie du compresseur haute pression (HPC)




FIGURE 3.12 – Vitesse physique du ventilateur




FIGURE 3.13 – Vitesse physique du noyau




FIGURE 3.14 – Pression statique à la sortie du compresseur haute pression (HPC)




FIGURE 3.15 – Rapport du débit de carburant à Ps30




FIGURE 3.16 – Vitesse corrigée du ventilateur




FIGURE 3.17 – Rapport de dérivation




FIGURE 3.18 – Enthalpie du prélèvement d'air




FIGURE 3.19 – Flux d'air de refroidissement des turbines haute pression




FIGURE 3.20 – Flux d’air de refroidissement des turbines basse pression

3.4.3 Observations sur les signaux des moteurs et des capteurs

Nous observons un signal fort dans les derniers cycles avant la défaillance d’un moteur, ce qui peut être quantifié à l’aide de différentes techniques. De plus, le capteur sm_9 (Physical core speed) (rpm) (figure 3.13) semble avoir des valeurs différentes pour chaque moteur, ce qui pourrait ne pas être utile pour notre analyse. Cependant, ne le supprimons pas pour l’instant.

3.4.4 Conclusion

D’après les méthodes appliquées (trendability, monotonocity, prognosability) et l’analyse des corrélations, voici les colonnes sélectionnées qui peuvent être considérées comme informatives :

- op_setting_1
- op_setting_2
- sm_2 (Température à la sortie du compresseur basse pression)
- sm_3 (Température à la sortie du compresseur haute pression)
- sm_4 (Température à la sortie de la turbine basse pression)
- sm_7 (Pression à la sortie du compresseur haute pression)
- sm_8 (Vitesse physique du ventilateur)
- sm_9 (Vitesse physique du noyau)
- sm_11 (Pression statique à la sortie du compresseur haute pression)
- sm_12 (Rapport du débit de carburant à Ps30)
- sm_13 (Vitesse corrigée du ventilateur)
- sm_15 (Rapport de dérivation)
- sm_17 (Enthalpie du prélèvement d’air)
- sm_20 (Flux d’air de refroidissement des turbines haute pression)
- sm_21 (Flux d’air de refroidissement des turbines basse pression)

Ces caractéristiques seront essentielles pour la construction et l’entraînement des modèles de machine learning dans les chapitres à venir. Dans les sections suivantes, nous examinerons deux approches principales :

- Une approche de régression pour estimer la durée de vie restante (RUL) des moteurs, en utilisant diverses méthodologies :
 - Modélisation de la dégradation exponentielle
 - RUL basé sur la similarité
 - Modèles classiques tels que la régression linéaire, SVM et Random Forest
- Une approche de classification pour évaluer l’état des moteurs, qui se décline en trois classes : Bon, Avertissement, et Danger.

Chapitre 4

Modélisation de la Dégradation Exponentielle pour la Prédiction de la RUL

Dans ce chapitre, nous abordons la modélisation de la dégradation exponentielle pour estimer la durée de vie utile restante (RUL) des moteurs. L'objectif est de capturer la tendance exponentielle de la dégradation en utilisant des indicateurs de santé dérivés des données. Cette approche repose sur plusieurs étapes, depuis la préparation des données jusqu'à la prédiction de la RUL. Nous nous concentrons également sur l'identification des moteurs présentant des comportements de dégradation similaires et la définition d'un seuil de panne.

4.1 Identification de l'Indicateur de Santé

L'objectif de cette section est de développer un indicateur de santé fiable pour surveiller l'état des équipements en fonction des données collectées.

4.1.1 Préparation des Données

Pour garantir une analyse robuste, nous avons appliqué plusieurs techniques de prétraitement :

- **Moyenne Glissante** : La méthode de la moyenne glissante a été utilisée pour réduire le bruit dans les données brutes. Cette étape permet d'obtenir des séries temporelles lissées, facilitant l'analyse des tendances.
- **Normalisation Min-Max** : Une normalisation Min-Max a ensuite été appliquée pour mettre les données à l'échelle, dans l'intervalle $[0, 1]$. Cette approche permet de comparer les variables sur une base commune tout en préservant les relations relatives entre les valeurs.

La relation utilisée pour la normalisation est la suivante :

$$X_{norm} = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

Ce choix est justifié par la simplicité d'interprétation des résultats et la stabilité des calculs.

4.1.2 Sélection des Caractéristiques

Les colonnes présentant une forte monotonie ont été sélectionnées pour refléter la dynamique des données et leur corrélation avec l'évolution du système. Nous avons défini un seuil de monotonie $\text{mon} > 0.055$, et retenu uniquement les colonnes répondant à ce critère.

```
feats = mon_df.column[mon_df.monotonicity > 0.055]
feats
✓ 0.0s

['sm_9', 'sm_11', 'sm_12', 'sm_4', 'sm_13', 'sm_8', 'sm_7', 'sm_15', 'sm_20', 'sm_21', 'sm_2', 'sm_17']
```

Cette démarche vise à ne conserver que les caractéristiques les plus pertinentes dans la construction de l'indicateur de santé.

4.1.3 Réduction de Dimensionnalité avec PCA

Pour fusionner les caractéristiques sélectionnées, une Analyse en Composantes Principales (PCA) a été appliquée. Nous avons choisi de retenir les trois premières composantes principales (PC1, PC2, PC3), représentant la majorité de la variance des données. Pour explorer les composantes principales, nous avons visualisé PC1, PC2, et PC3 entre eux.




FIGURE 4.1 – Composantes principales

Cette visualisation a révélé une relation significative entre les deux premières composantes principales (PC1 et PC2).

Visualisation des Composantes Principales PC1 et PC2

Une visualisation des relations entre les deux premières composantes principales (PC1 et PC2) a été réalisée en fonction de la durée de vie restante (RUL). L'exemple ci-dessous illustre cette relation pour un moteur particulier :




FIGURE 4.2 – PC1 et PC2 en fonction de la RUL

Les résultats montrent une corrélation significative entre PC1, PC2 et RUL, suggérant que PC1 peut servir d'indicateur de santé fiable.

Utilisation de PC1 comme Indicateur de Santé

Nous avons choisi d'adopter la première composante principale (PC1) comme indicateur principal de santé. La figure suivante illustre l'évolution de PC1 au fil des cycles pour un moteur donné :




FIGURE 4.3 – Évolution de l'indicateur de santé (PC1) par cycle

4.1.4 Visualisation des Tendances des Moteurs

Pour mieux comprendre l'évolution des indicateurs de santé (PC1) pour différents moteurs, nous avons sélectionné 12 moteurs au hasard et avons tracé l'évolution du PC1 pour chaque moteur au fil du temps. Ce processus a permis de visualiser la tendance générale du PC1 avant et au moment de défaillance du moteur.




FIGURE 4.4 – Indicateurs de santé pour plusieurs moteurs

En observant les courbes générées pour les différents moteurs, nous constatons que le PC1 suit généralement une croissance progressive, semblable à une courbe exponentielle, indiquant une amélioration ou une stabilité de l'état du moteur. Cependant, à l'approche de la défaillance, les valeurs du PC1 se concentrent autour de 2, ce qui marque une réduction notable de l'indicateur de santé. Ce phénomène peut être observé juste avant que le moteur ne tombe en panne, suggérant que PC1 est un indicateur pertinent pour détecter l'usure des moteurs et prédire leur défaillance.

4.1.5 Détermination d'un Seuil de Défaillance

Visualisation des Valeurs des Indicateurs de Santé selon Différentes Règles

Afin d'explorer la distribution des valeurs de l'indicateur de santé (PC1) en fonction de la durée de vie restante (RUL), nous avons tracé les distributions des valeurs de PC1 pour différentes valeurs de RUL. Ces visualisations permettent de mieux comprendre comment les valeurs de l'indicateur de santé évoluent à mesure que le RUL diminue.




FIGURE 4.5 – Distribution de l'indicateur de santé (PC1) selon les niveaux de RUL

Comme nous pouvons le constater dans les graphiques ci-dessus, la dispersion des valeurs de l'indicateur de santé (PC1) diminue à mesure que le RUL approche de zéro. Cela montre que l'indicateur devient plus concentré au fur et à mesure que le moteur approche de sa défaillance, ce qui est un signe de dégradation du système.

Seuil de Défaillance

Sur la base des observations précédentes, le seuil de défaillance a été déterminé à partir de la moyenne des valeurs de PC1 lorsque le RUL est égal à zéro. Ce seuil correspond à une valeur de $\mu = 1.97$, avec un écart-type associé de $\sigma = 0.11$.

4.2 Modèle de l'Indicateur de Santé (Exponentiel)

Dans cette section, nous appliquons un modèle exponentiel pour modéliser l'évolution de l'indicateur de santé (Health Indicator, HI) au fil du temps pour chaque moteur. Ce modèle a pour but de capturer la dégradation de l'indicateur de santé en fonction du temps, en s'appuyant sur la forme exponentielle de la courbe de dégradation des moteurs.

4.2.1 Modélisation

Le modèle exponentiel que nous utilisons est défini par l'expression suivante :

$$HI(t) = A \cdot e^{-\lambda t} + B$$

où A , B , et λ sont des constantes qui caractérisent respectivement le niveau de base, l'amplitude, et le taux de dégradation exponentielle.

L'objectif principal de cette modélisation est d'ajuster les paramètres A , B , et λ pour chaque moteur à partir des données de son cycle et de l'indicateur de santé $pc1$. Nous cherchons à minimiser l'erreur entre les valeurs observées de l'indicateur de santé et celles prédites par le modèle.

4.2.2 Ajustement du Modèle pour Chaque Moteur

- Pour chaque moteur de notre jeu de données, nous avons utilisé la méthode des moindres carrés pour ajuster le modèle exponentiel.
- L'optimisation permet de déterminer les paramètres A , B , et λ qui minimisent la différence entre les données observées et les prédictions du modèle. Cette procédure a été appliquée à tous les moteurs, de manière à obtenir les paramètres de dégradation pour chaque moteur.

engine		A	B	lambda_
0	1	-0.880568	0.075135	0.019556
1	2	-1.337524	0.068601	0.013763
2	3	-0.937691	0.024805	0.026614
3	4	-0.516098	0.010315	0.029437
4	5	-1.283207	0.062999	0.014831
...	...	...	...	...
95	96	-0.859759	0.077333	0.010943
96	97	-0.747404	0.004845	0.031526
97	98	-1.213762	0.122798	0.021208
98	99	-0.876814	0.056936	0.021865
99	100	-0.608983	0.093579	0.017105

FIGURE 4.6 – Les paramètres A , B , et λ pour chaque moteur

Le graphique ci-dessous présente la comparaison entre l'indicateur de santé observé et l'indicateur de santé prédit pour un moteur donné, ainsi que la ligne de seuil de défaillance.




FIGURE 4.7 – L’indicateur de santé observé et prédit pour un moteur donné (moteur 23)

L’application de ce modèle exponentiel permet de simuler la dégradation des moteurs au fil du temps et de prédire l’évolution de leur indicateur de santé. On peut utiliser cette modélisation pour anticiper les pannes et améliorer la gestion de la maintenance des moteurs.

4.3 Prédiction de la Durée de Vie Restante (RUL)

Cette section se concentre sur la prédiction de la Durée de Vie Restante (RUL) pour les unités de test en utilisant un modèle de dégradation exponentielle.

4.3.1 Méthodologie

Étape 1 - Préparation des données de test :

- Nous avons commencé par préparer les données de test en effectuant l’Analyse en Composantes Principales (PCA) et en extrayant la première composante principale (PC1).
- Les PCA ont été calculés en utilisant les mêmes colonnes que celles utilisées pour l’entraînement (les colonnes sélectionnées présentant une monotonie supérieure à 0.055), afin d’assurer une cohérence.
- Les données ont ensuite été normalisées à l’aide de la méthode Min-Max, suivant exactement le même procédé appliqué aux données d’entraînement.

Étape 2 - Ajustement du modèle : Pour chaque moteur de test, nous avons ajusté un modèle exponentiel en utilisant les paramètres A , B , λ obtenus à partir des données d’entraînement comme référence. Les paramètres sont ajustés à l’aide des données d’indicateur de

santé (pc1) et des cycles, avec des bornes définies par les valeurs des 25e et 75e percentiles des modèles exponentiels obtenus à partir des données d'entraînement.

Remarque : L'utilisation des paramètres obtenus à partir de l'entraînement comme référence permet de tirer parti des connaissances déjà acquises sur les comportements typiques des moteurs. Cela garantit une certaine cohérence entre les modèles appliqués aux données d'entraînement et de test. De plus, en définissant les bornes des paramètres selon les 25e et 75e percentiles, nous avons cherché à capturer la variabilité naturelle des données tout en évitant les valeurs extrêmes ou aberrantes. Cette approche assure que l'ajustement reste réaliste et représentatif, tout en évitant un surajustement ou une sous-estimation des dynamiques réelles des moteurs.

Étape 3 - Calcul du nombre total de cycles jusqu'à la défaillance : Nous avons calculé le nombre total de cycles nécessaires pour que l'indicateur de santé atteigne le seuil de défaillance à l'aide de la formule :

$$\text{total_cycles} = \frac{\log \left(\frac{\text{threshold} - A}{B} \right)}{\lambda}$$

Étape 4 - Estimation de la RUL : La Durée de Vie Restante (RUL) est calculée comme suit :

$$\text{RUL} = \text{total_cycles} - \text{cycle_actuel} \quad (4.1)$$

Répéter les étapes 2 à 4 pour tous les moteurs de test.

Le tableau ci-dessous montre un aperçu des résultats obtenus pour quelques moteurs de test.

	engine	A	B	lambda_	Pred_RUL	True_RUL
0	1	-0.858803	0.079980	0.023414	125.422608	112
1	2	-0.303772	0.079980	0.023414	98.124962	98
2	3	-0.249964	0.079980	0.019196	51.332748	69
3	4	-0.364340	0.079980	0.019606	70.261633	82
4	5	-0.282076	0.054107	0.023406	65.458355	91

FIGURE 4.8 – Comparaison des Prédictions de RUL pour Quelques Moteurs de Test

Le graphique suivant présente les résultats pour un moteur spécifique sélectionné aléatoirement. Il compare l'évolution réelle de l'indicateur de santé (HI) avec la dégradation prédite par un

modèle exponentiel, et inclut le seuil de défaillance ainsi que le RUL réel pour le moteur en question.




FIGURE 4.9 – Comparaison entre l'Indicateur de Santé Réel et la Dégradation Prédite pour le Moteur 84

4.3.2 Résultats et Analyse des Performances

Comparaison entre les RUL prédit et réel :




FIGURE 4.10 – Comparaison entre la Durée de Vie Restante (RUL) Prédit et Réelle




FIGURE 4.11 – Comparaison entre la Durée de Vie Restante (RUL) Prédit et Réelle pour Chaque Moteur

Métriques d’erreur :

Métrique	Erreur Absolue Moyenne (MAE)	Erreur Quadratique Moyenne (RMSE)	Coefficient de Détermination (R^2)
Valeur	20.95	30.51	0.46

TABLE 4.1 – Métriques d’évaluation du modèle

4.3.3 Analyse des résultats

- **Amélioration par rapport à une approche basée uniquement sur le temps de fonctionnement (loi gamma et log-normal) :** Cette méthode utilise l’historique des indicateurs de santé pour ajuster un modèle exponentiel, ce qui permet de mieux capturer les tendances de dégradation. Cela se traduit par des prévisions de RUL plus fiables, surtout pour les moteurs ayant fonctionné un nombre significatif de cycles.
- **Limites pour les moteurs en début de vie :** Lorsque l’historique est limité (par exemple, un moteur ayant fonctionné seulement 10 cycles), le modèle ne dispose pas d’une tendance de dégradation claire, rendant les prévisions moins précises. En revanche, pour un moteur ayant fonctionné 100 cycles ou plus, l’indicateur de santé montre une tendance croissante bien définie, ce qui permet au modèle d’estimer le RUL de manière plus précise.

Les graphiques suivants comparent le RUL prédit et le RUL réel d’un moteur dans deux scénarios différents : le premier graphique présente un moteur ayant effectué plus de 200 cycles, tandis que le deuxième graphique concerne un moteur ayant réalisé moins de 30 cycles. Ces

deux graphiques montrent comment le RUL prédit évolue par rapport au RUL réel dans chaque cas.




FIGURE 4.12 – RUL Prédit et Réel pour un Moteur avec Plus de 200 Cycles




FIGURE 4.13 – RUL Prédit et Réel pour un Moteur avec Moins de 30 Cycles

4.3.4 Conclusion

En conclusion, l'approche basée sur l'historique des indicateurs de santé et l'ajustement d'un modèle exponentiel présente des avantages considérables par rapport à une méthode simple reposant uniquement sur le temps de fonctionnement, notamment pour les moteurs ayant effectué un nombre conséquent de cycles.

Cette approche, bien que moins précise pour les moteurs moins âgés, bénéficie d'une grande flexibilité qui permet d'ajuster les prévisions en fonction des caractéristiques spécifiques des moteurs à différents stades de leur cycle de vie. Elle démontre ainsi une forte capacité à prédire la RUL de manière plus fiable et plus précise.

Chapitre 5

Prédiction du RUL Basée sur l'Analyse de Similarités Multi-Facteurs

Après avoir abordé l'approche de la modélisation de la dégradation exponentielle, ce chapitre se concentre sur une méthodologie avancée : l'Analyse de Similarités Multi-Facteurs (ASMF). Cette approche permet de prédire le RUL de manière plus précise en intégrant plusieurs paramètres mesurés à partir de capteurs, notamment ceux liés aux Conditions d'Activité (CA) : l'ensemble des paramètres de la machine contrôlables par les opérateurs (vitesse, pression, alimentation) et aux États du Système (ES) : les grandeurs physiques intrinsèques à l'équipement non contrôlables par l'opérateur (vibration, qualité d'huile, température résiduelle).

L'ASMF repose sur l'idée que la similarité entre différents moteurs ou différents états d'un même moteur, observée à travers des séries temporelles, peut fournir des informations cruciales pour prédire la durée de vie restante. Cette méthodologie s'appuie sur plusieurs étapes clés :

1. **Identification des Régimes de Fonctionnement** : Dans un premier temps, les moteurs sont regroupés en fonction de leurs conditions de fonctionnement, à savoir les CA, afin de normaliser les données selon chaque régime de fonctionnement.
2. **Identification des Paramètres Prépondérants** : Une fois les régimes de fonctionnement identifiés, il est crucial de sélectionner les capteurs les plus pertinents pour prédire la fin de vie des moteurs. Cette sélection se base sur les corrélations et les tendances des données des capteurs, en isolant les paramètres ayant le plus grand impact sur la durée de vie restante.
3. **Fusion des Données** : L'étape suivante consiste à agréger les données provenant de différents capteurs pour générer un indicateur de survie global pour chaque moteur. Cet indicateur est essentiel pour mesurer l'état de santé du moteur au fil du temps et pour prédire la probabilité de défaillance.
4. **Prédiction du RUL** : Enfin, la prédiction du RUL est réalisée en utilisant une approche basée sur les k voisins les plus proches (k-NN). En comparant les courbes de survie des différents moteurs, cette méthode permet d'identifier celles dont les comportements sont

les plus similaires à celui de la machine en cours d'analyse, fournissant ainsi une estimation fiable du RUL.

5.1 Analyse de Similarités Multi-Facteurs (ASMF)

5.1.1 Identification des Régimes de Fonctionnement

Dans notre cas, les Conditions d'Activité (CA) sont représentées par les paramètres `op_setting_1` et `op_setting_2`. Il existe un seul régime de fonctionnement. Par conséquent, une normalisation des données a été réalisée à l'aide de la méthode de normalisation en Z afin de garantir l'homogénéité des valeurs des différents paramètres.

La normalisation en Z, également connue sous le nom de normalisation standard, est une technique utilisée pour transformer les données afin qu'elles aient une moyenne de 0 et un écart-type de 1. Cela permet de standardiser différentes caractéristiques en éliminant les écarts dus à leurs différentes échelles. Pour une donnée d'une caractéristique donnée X , la normalisation en Z est définie par la formule suivante :

$$Z = \frac{X - \mu}{\sigma}$$

Où :

- Z : valeur normalisée (ou score Z) pour X ,
- X : valeur originale de la donnée,
- μ : moyenne des valeurs de la caractéristique X ,
- σ : écart-type des valeurs de la caractéristique X .

5.1.2 Sélection des Paramètres Prépondérants

La sélection des paramètres a été réalisée lors de la sélection des caractéristiques informatives dans le chapitre 4. Les paramètres retenus sont considérés comme les plus pertinents pour la prédiction de la durée de vie restante. Ils servent d'entrée pour les étapes de fusion et de modélisation.

5.1.3 Fusion des Données

Dans un premier temps, nous avons élaboré un modèle de dégradation linéaire pour intégrer les différentes caractéristiques identifiées. Supposons que l'état de santé d'une unité se dégrade de manière linéaire. Pour modéliser la dégradation d'une unité de manière linéaire, on peut définir l'Indicateur de Santé (HI) comme suit :

$$HI = 1 - \frac{\text{Cycle Actuel}}{\text{Cycle Maximal}}$$




FIGURE 5.1 – Indicateur de Santé Initial pour les moteurs 70 à 100

5.1.4 Construction d'un Modèle de Régression Linéaire pour l'Indicateur de Santé

Un modèle de régression linéaire est utilisé pour modéliser la relation entre les caractéristiques sélectionnées et l'indicateur de santé (HI).

$$\text{New HI} = \sum_{i=1}^n (\text{coef}_i * \text{feature}_i)$$

Les coefficients de la régression linéaire, obtenus lors de l'entraînement du modèle, servent à pondérer les caractéristiques. Ces coefficients illustrent l'impact relatif de chaque caractéristique sur l'indicateur de santé et montrent leur contribution à la dégradation de l'unité. Une caractéristique fortement corrélée à la dégradation recevra un coefficient plus élevé, tandis qu'une caractéristique moins influente aura un coefficient plus faible. Cette méthode assure que le nouvel indicateur de santé reflète fidèlement l'état de l'unité en prenant en compte les informations des caractéristiques les plus pertinentes.




FIGURE 5.2 – Indicateur de Santé Final pour les Unités 71 à 100

5.1.5 Lissage de l'Indicateur de Santé Final

Un lissage a été appliqué en calculant une moyenne mobile de l'indicateur de santé final.




FIGURE 5.3 – Indicateur de Santé Final et Points de Défaillance

5.1.6 Modélisation de l'Évolution de l'Indicateur de Santé

Dans cette étape, une fonction polynomiale de second ordre est ajustée sur les indicateurs de santé (HI) afin de modéliser leur évolution au fil des cycles de fonctionnement. La fonction est définie par l'équation suivante :

$$y = \theta_0 + \theta_1 x + \theta_2 x^2$$

Où :

- y représente l'indicateur de santé (HI),
- x correspond au cycle de fonctionnement,
- $\theta_0, \theta_1, \theta_2$ sont les coefficients du polynôme, déterminés par un ajustement sur les données réelles.

5.1.7 Estimation des Coefficients

Les coefficients du polynôme sont calculés à l'aide de la méthode des moindres carrés, qui consiste à minimiser la somme des erreurs quadratiques entre les valeurs observées et celles prédites par le modèle. Cette méthode permet de déterminer les coefficients optimaux ($\theta_0, \theta_1, \theta_2$) qui représentent l'ajustement le plus précis de la courbe.




FIGURE 5.4 – Comparaison de l'Indicateur de Santé Réel et Ajusté pour différents moteurs

5.1.8 Prédiction du RUL : Construction d'un modèle RUL basé sur la similarité

L'objectif de cette étape est de prédire la durée de vie restante (RUL) des moteurs en se basant sur la similarité des indicateurs de santé entre les moteurs du jeu de données d'entraînement et de test. Cette approche repose sur la comparaison des modèles polynomiaux

ajustés aux indicateurs de santé, et sur l'utilisation de la méthode des voisins les plus similaires pour prédire le RUL.

Étapes Méthodologiques

- Générer un indicateur de santé : en multipliant les poids des caractéristiques sélectionnées dans les données de test.

$$HI = \sum_{i=1}^n (\text{coef}_i * \text{feature}_i)$$

- Application de la moyenne roulante sur l'indicateur de santé : Afin de réduire le bruit et d'obtenir une courbe plus lissée de l'indicateur de santé, nous appliquons une moyenne roulante sur l'indicateur de santé calculé pour chaque moteur.
- Comparer les modèles polynomiaux ajustés avec les indicateurs de santé des données de test : et trouver les résidus en norme 1 en utilisant l'équation ci-dessous.

$$d(i, j) = \|y_i - \hat{Y}_{ij}\|_1$$

Où :

$\hat{Y}_{ij}$: l'indicateur de santé ajusté prédit par le modèle polynomial pour l'unité j et le moteur i .

- **Calculer le score de similarité en utilisant la formule suivante :**

$$\text{Score}(i, j) = \exp(-d(i, j)^2)$$

- **Sélection des modèles les plus similaires :** Une fois que nous avons calculé les scores de similarité, nous sélectionnons les K modèles les plus similaires pour chaque moteur de test.




FIGURE 5.5 – 5 Modèles les Plus Similaires pour un moteur de test

Calcul de la prédiction du RUL

Enfin, la prédiction du RUL est calculée en soustrayant le cycle actuel du nombre total de cycles des unités les plus similaires. Nous utilisons la médiane des cycles de vie totaux des moteurs similaires (médiane des K modèles les plus proches) pour déterminer le RUL estimé, car cela donne des résultats plus robustes par rapport à la moyenne.

Choix du meilleur K pour la prédiction du RUL

Dans cette étape, nous utilisons les valeurs de RMSE (Root Mean Squared Error) et de R^2 (coefficient de détermination) pour évaluer la performance du modèle de prédiction du RUL en fonction de la valeur de K . Nous testons différentes valeurs de K allant de 1 à 50, et pour chaque valeur, nous calculons R^2 et le RMSE.




FIGURE 5.6 – Évolution de R^2 et RMSE en fonction de K

Dans ce cas, la meilleure valeur de K selon le RMSE et R^2 est $K = 2$, ce qui nous permet d'obtenir la meilleure précision dans la prédiction du RUL.

5.2 Résultats et Analyse des Performances

5.2.1 Comparaison entre les RUL prédit et réel




FIGURE 5.7 – Comparaison entre la durée de vie restante (RUL) Prédit et réelle




FIGURE 5.8 – Comparaison entre la durée de vie restante (RUL) Prédit et réelle pour Chaque Moteur

5.2.2 Métriques d'erreur

Métrique	Erreur Absolue Moyenne (MAE)	Erreur Quadratique Moyenne (RMSE)	Coefficient de Détermination (R^2)
Valeur	17.93	22.70	0.70

5.2.3 Analyse des résultats

Les résultats obtenus pour la prédiction du RUL avec cette méthode de similarité sont satisfaisants, surtout en comparaison avec les approches précédentes utilisées pour la prédiction de la durée de vie restante des moteurs. Ces résultats montrent une bonne précision du modèle, avec un faible niveau d'erreur et un coefficient de détermination assez élevé. L'utilisation de la méthode de similarité pour trouver les unités les plus proches permet d'obtenir des prédictions plus robustes et adaptées aux spécificités des moteurs.

5.3 Conclusion

Dans ce chapitre, nous avons examiné la méthode de prédiction du RUL fondée sur la similarité, qui a donné des résultats prometteurs, surtout pour les moteurs ayant effectué plusieurs cycles. Cette approche s'avère particulièrement efficace lorsque l'historique des moteurs est suffisamment détaillé pour permettre une comparaison pertinente avec d'autres moteurs similaires.

Cependant, tout comme la méthode de dégradation exponentielle, elle présente certaines limites lorsqu'il s'agit de moteurs avec peu ou pas d'historique. Dans ces situations, l'ajustement du modèle peut être moins précis, car il n'existe pas assez de données pour réaliser des comparaisons fiables. L'approche de similarité dépend également du choix du nombre de voisins

K , et un mauvais réglage de ce paramètre peut affecter la performance du modèle, surtout pour les moteurs qui n'ont pas un historique de cycles assez étendu pour permettre une estimation correcte de leur RUL.

Dans les chapitres suivants, nous nous pencherons sur l'application de modèles tels que les machines à vecteurs de support (SVM), la régression linéaire et les forêts aléatoires (Random Forest). Nous examinerons également des méthodes de classification pour prédire les états des moteurs, notamment les catégories "Bon", "Avertissement" et "Danger", afin d'améliorer la détection et la gestion des pannes des moteurs.

Chapitre 6

Modèles Classiques pour la Prédiction et Classification de l'État des Moteurs

Après avoir examiné des méthodes basées sur la similarité et la dégradation exponentielle pour estimer la durée de vie restante (RUL) des moteurs, nous nous tournons maintenant vers l'utilisation de modèles classiques de machine learning. Parmi ces modèles, nous trouvons la régression linéaire, les machines à vecteurs de support (SVM) et les forêts aléatoires (Random Forest), qui sont couramment employés dans les domaines de l'analyse prédictive et de la classification.

Dans ce chapitre, nous appliquerons ces techniques à deux axes principaux :

- Prédiction du RUL : Utilisation de modèles supervisés pour estimer la durée de vie restante des moteurs avec une précision améliorée.
- Classification de l'état des moteurs : Adoption d'une approche de classification pour diviser les moteurs en trois états distincts – "Bon", "Avertissement" et "Danger". Cette méthode permet d'évaluer le niveau de dégradation des moteurs et de prévoir les interventions de maintenance nécessaires.

6.1 Modèles supervisés : Régression Linéaire, SVM et Random Forest

6.1.1 Préparation de données

Avant d'entamer l'entraînement des modèles supervisés, les données ont été soigneusement préparées en respectant les étapes suivantes :

- **Sélection des caractéristiques pertinentes** : Les variables les plus significatives ont été retenues à partir de l'analyse réalisée lors de l'étape de sélection des caractéristiques (Chapitre 4).

- **Normalisation Min-Max** : Une mise à l'échelle des caractéristiques a été effectuée pour les ramener dans l'intervalle $[0, 1]$, favorisant ainsi une convergence optimale des modèles.
- **Calcul du RUL (Remaining Useful Life)** : Pour chaque ligne de données, la durée de vie restante a été calculée en appliquant la formule suivante :

$$\text{RUL} = \text{Max de cycle du moteur} - \text{Cycle actuel}$$

```
data['rul'] = data.groupby('engine')['time'].transform('max') - data['time']
```

6.1.2 Régression Linéaire

La régression linéaire est une méthode de modélisation permettant d'établir une relation linéaire entre une variable continue dite "variable expliquée" ou dépendante et un ensemble d'autres variables continues dites "variables explicatives" ou indépendantes. Plus spécifiquement elle propose un modèle explicatif qui permet de prédire la variable dépendante en fonction des variables indépendantes.

Entraînement : Le modèle a été entraîné sur les données d'entraînement normalisées. Les performances ont ensuite été évaluées en termes de RMSE (Root Mean Squared Error) et de R^2 (coefficient de détermination).

Résultats :

- Ensemble d'entraînement : $\text{RMSE} = 40.43$ et $R^2 = 65.54\%$
- Ensemble de test : $\text{RMSE} = 31.36$ et $R^2 = 43.05\%$

6.1.3 Support Vector Machine (SVM)

Les SVMs sont une famille d'algorithmes d'apprentissage automatique qui permettent de résoudre des problèmes tant de classification que de régression ou de détection d'anomalie. Comme le montre la figure ci-dessous, leur principe est simple : il ont pour but de séparer les données en classes à l'aide d'une frontière aussi « simple » que possible, de telle façon que la distance entre les différents groupes de données et la frontière qui les sépare soit maximale. Cette distance est aussi appelée « marge » et les SVMs sont ainsi qualifiés de « séparateurs à vaste marge », les « vecteurs de support » étant les données les plus proches de la frontière.




FIGURE 6.1 – Support Vector Machine (SVM)

Entraînement : Le modèle a été appliqué sur l'ensemble d'entraînement. Les performances initiales sur les ensembles d'entraînement et de test sont les suivantes :

- Ensemble d'entraînement : $RMSE = 42.91$ et $R^2 = 61.54\%$
- Ensemble de test : $RMSE = 26.15$ et $R^2 = 60.41\%$

Ajustement des hyperparamètres : Le réglage des hyperparamètres consiste à identifier et à choisir les meilleurs hyperparamètres pour entraîner un modèle. Un bon réglage des hyperparamètres permet de réduire la fonction de perte des modèles, ce qui signifie que ceux-ci sont entraînés pour atteindre la meilleure précision possible.

Les principaux hyperparamètres ajustés sont :

- **C** : Ce paramètre contrôle la régularisation du modèle, équilibrant la complexité du modèle (variance) et la minimisation des erreurs (biais).
- **Gamma** : Définit l'impact d'un seul point de données sur la décision. Une valeur élevée de gamma signifie que chaque point influence fortement la décision, alors qu'une valeur basse le fait moins.
- **Kernel** : Fonction noyau utilisée pour transformer les données. Les options incluent des noyaux linéaires, polynomiaux et radiaux (RBF).

Résultats après ajustement :

- Ensemble d'entraînement : $RMSE = 37.85$ et $R^2 = 69.80\%$
- Ensemble de test : $RMSE = 24.91$ et $R^2 = 64.06\%$

6.1.4 Modèle Random Forest

Le Random Forest (La forêt d'arbres décisionnels) est un algorithme de machine learning couramment utilisé, qui combine les résultats de plusieurs arbres de décision pour obtenir un résultat unique. Sa facilité d'utilisation et sa flexibilité ont favorisé son adoption, car il gère à la fois les problèmes de classification et de régression.




FIGURE 6.2 – Illustration de l'algorithme Random Forest

Hyperparamètres ajustés : Les principaux hyperparamètres ajustés sont :

- **n_estimators** : Le nombre d'arbres dans la forêt. Plus ce nombre est élevé, plus le modèle est stable, mais cela augmente également le temps de calcul.
- **max_depth** : La profondeur maximale des arbres, qui limite leur complexité et aide à éviter le surapprentissage.
- **min_samples_split** : Le nombre minimum d'échantillons requis pour diviser un nœud interne.
- **min_samples_leaf** : Le nombre minimum d'échantillons dans une feuille pour éviter des branches trop spécifiques.
- **max_features** : Le nombre maximum de caractéristiques considérées lors de la division d'un nœud.

Résultats après ajustement :

- Ensemble d'entraînement : $RMSE = 30.05$ et $R^2 = 80.97\%$

— Ensemble de test : $RMSE = 25.03$ et $R^2 = 63.72\%$

6.1.5 Résultats et Analyse

Comparaison des métriques d'erreur :

Modèle	Erreur quadratique moyenne (RMSE)	Coefficient de détermination (R^2)
Régression linéaire	31.36	0.43
Random Forest	25.03	0.63
SVM	24.91	0.64

Nous observons que le modèle SVM offre les meilleurs résultats en termes de performance sur l'ensemble de test. En particulier, le SVM présente une meilleure précision avec des métriques de RMSE et de R^2 qui surpassent celles des autres modèles, confirmant ainsi son efficacité pour cette tâche de prédiction.

Visualisation de la relation entre le RUL prédit par SVM et le RUL réel :




FIGURE 6.3 – Comparaison entre la durée de vie restante (RUL) Prédit par SVM et réelle




FIGURE 6.4 – Comparaison entre la durée de vie restante (RUL) Prédit par SVM et réelle pour Chaque Moteur

6.2 II. Approche de Classification pour la Prédiction de l'État des Moteurs

Dans cette approche, au lieu de prédire directement la durée de vie restante (RUL), nous utilisons une méthode de classification pour évaluer l'état des moteurs. Cette méthode permet de classer les moteurs en trois états distincts :

- **Bon** : lorsque le RUL est supérieur à 40 cycles, indiquant un moteur en bonne santé.
- **Avertissement** : lorsque le RUL se situe entre 10 et 40 cycles, signalant une éventuelle intervention à prévoir.
- **Danger** : lorsque le RUL est inférieur à 10 cycles, nécessitant une intervention immédiate.

Les valeurs seuils (≤ 10 , entre 10 et 40, et ≥ 40) ont été fixées de manière empirique en l'absence de recommandations ou d'informations provenant d'experts dans le domaine. Cette catégorisation facilite l'interprétation des résultats et permet une prise de décision rapide en matière de maintenance.

6.2.1 1. Préparation de données

Génération de la variable d'état : une nouvelle variable, appelée *État*, est créée selon les seuils définis précédemment.

- $État = 2$ si $RUL \geq 40$ (**Bon**).
- $État = 1$ si $10 \leq RUL \leq 40$ (**Avertissement**).
- $État = 0$ si $RUL \leq 10$ (**Danger**).

```

conditions = [
    (test_rul['RUL'] > 40),
    (test_rul['RUL'] >= 10) & (test_rul['RUL'] <= 40),
    (test_rul['RUL'] < 10)
]
choices = [2, 1, 0] # Bon, Avertissement, Danger
test_rul['État'] = np.select(conditions, choices)

```

6.2.2 2. Entraînement d'un modèle SVM pour la classification

Une fois la variable *État* générée, un modèle SVM (Support Vector Machine) est ensuite entraîné pour prédire la classe correspondante à l'état du moteur. Les données sont normalisées (Min-Max Scaling) avant l'entraînement, tout comme pour les modèles précédents.

Évaluation des performances : Les performances du modèle SVM sont évaluées à l'aide de métriques classiques en classification :

- **Matrice de confusion :** La matrice de confusion (ou matrice d'erreur) est une méthode qui permet de visualiser les résultats d'un algorithme de classification. Plus précisément, il s'agit d'une table qui décompose le nombre d'instances de vérité terrain d'une classe donnée par rapport au nombre d'instances de classes prédites.




FIGURE 6.5 – Matrice de confusion

- **TP (Vrais Positifs) :** Prédictions correctes pour une classe donnée.
- **FP (Faux Positifs) :** Prédictions incorrectes, où la classe prédite diffère de la classe réelle.
- **FN (Faux Négatifs) :** Classe réelle qui a été manquée.
- **TN (Vrais Négatifs) :** Prédictions correctes pour toutes les autres classes.
- **Accuracy (Précision globale) :** L'accuracy mesure le pourcentage de prédictions cor-

rectes par rapport à l'ensemble des prédictions effectuées. Elle est définie par :

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Precision (Précision)** : La précision mesure la proportion de prédictions positives correctes pour une classe donnée. Dans notre cas, cela signifie combien de fois le modèle a correctement prédit un moteur en "Danger" ou "Avertissement" parmi toutes ses prédictions pour ces états.

$$\text{Precision} = \frac{TP}{TP + FP}$$

- **Recall (Rappel ou Sensibilité)** : Le rappel mesure la capacité du modèle à identifier tous les exemples pertinents d'une classe donnée. Cela correspond à la proportion de moteurs effectivement en "Danger" ou "Avertissement" que le modèle a correctement identifiés.

$$\text{Recall} = \frac{TP}{TP + FN}$$

Quelle métrique privilégier dans le contexte des moteurs turbo-fan ?

Dans le cadre de la prédiction des états des moteurs turbo-fan, les métriques à considérer varient selon les objectifs :

- **Danger (Critique)** : Le rappel (Recall) est primordial pour cette catégorie, car il est essentiel de ne pas négliger un moteur en danger afin d'éviter des pannes catastrophiques. Un faible rappel dans ce cas signifierait que des moteurs critiques pourraient passer inaperçus.
- **Avertissement** : La précision pourrait être cruciale pour réduire les fausses alertes et éviter des interventions inutiles.
- **Bon** : Un équilibre entre précision et rappel (via l'accuracy ou le F1-score) est suffisant, car cette catégorie est généralement moins critique.

6.2.3 3. Résultats et Analyse des Performances

Précision globale : Le modèle SVM atteint une précision globale (accuracy) de 85%, ce qui indique que 85% des prédictions faites par le modèle sont correctes sur l'ensemble de test.

Matrice de confusion :




FIGURE 6.6 – Matrice de confusion

Métriques par classe :

Classe	Précision	Rappel	F1-Score
Danger	0.86	0.92	0.89
Avertissement	0.59	0.80	0.68
Bon	0.97	0.85	0.90

TABLE 6.1 – Métriques du modèle pour chaque classe

Interprétation des métriques :

Classe « **Danger** » :

- Avec une précision de 86% et un rappel de 92%, le modèle se distingue par son efficacité à identifier les moteurs en état critique.
- Le F1-score élevé (89%) atteste d'un bon équilibre entre la précision et le rappel pour cette catégorie, ce qui est essentiel pour ne pas négliger les moteurs en situation dangereuse.

Classe « **Avertissement** » :

- La précision pour cette classe est plutôt faible (59%), ce qui signifie que le modèle a parfois du mal à distinguer les états "Avertissement" des classes "Danger" ou "Bon".
- Cependant, un rappel de 80% indique que le modèle réussit à détecter la plupart des moteurs réellement en état d'avertissement, même si certaines de ses prédictions ne sont pas tout à fait correctes.

Classe « **Bon** » :

- Le modèle est très efficace pour détecter les moteurs en bon état, affichant une précision élevée de 97%.

- Cependant, un rappel légèrement inférieur de 85% indique qu'il y a quelques erreurs où des moteurs jugés "bons" sont incorrectement classés en "avertissement".

Analyse globale :

- Le modèle est très fiable pour prédire les moteurs dans des états extrêmes ("Danger" et "Bon").
- Les performances sur la classe intermédiaire "Avertissement" sont moins précises, ce qui pourrait être attribué à une ambiguïté dans les données ou à un chevauchement dans les caractéristiques.
- L'équilibre global des métriques (Précision globale : 85%) indique que le modèle peut être utilisé efficacement comme un outil d'aide à la décision pour évaluer l'état des moteurs.

Chapitre 7

Développement d'un Tableau de Bord interactif pour le Suivi et la Visualisation des États des Moteurs

Pour rendre les résultats des analyses précédentes exploitables, ce chapitre se concentre sur la création d'un tableau de bord interactif. L'objectif principal est de fournir une interface intuitive qui permettra de :

- Visualiser les prédictions du **RUL (Remaining Useful Life)** et l'état des moteurs.
- Suivre les **indicateurs de santé** pour évaluer l'état actuel des moteurs.
- Analyser la **dégradation exponentielle** des moteurs afin de détecter les tendances de dégradation.
- Afficher des **moteurs similaires** grâce à des approches basées sur la similarité.
- Suivre plusieurs **indicateurs clés de performance (KPI)**, tels que la fiabilité et les probabilités de défaillance.
- Gérer efficacement les **cycles de maintenance** en fonction des prédictions fournies.

Le tableau de bord intégrera les différents modèles développés, combinant les résultats du chapitre précédent avec :

- L'**analyse statistique** des temps de fonctionnement.
- Les approches de **dégradation exponentielle**.
- Les méthodes basées sur la **similarité**.
- Les prédictions de **régression et de classification**.

Il permettra également d'afficher des **visualisations dynamiques** pour une meilleure interprétation des résultats et une prise de décision plus éclairée.

7.1 Vue Globale : Synthèse des états des moteurs




FIGURE 7.1 – Première page - Vue Globale

Cette première page met en lumière l'état général des moteurs en opération et leur répartition en fonction de leur performance.

Nombre total de moteurs en opération

Le système suit un total de **100 moteurs**. Cette métrique constitue la base de l'analyse et reflète l'ensemble des moteurs en service, indépendamment de leur état.

Répartition des états

- **59 moteurs (59 %)** sont en **bon état**. Ces moteurs fonctionnent de manière optimale et ne nécessitent aucune action immédiate.
- **27 moteurs (27 %)** sont en **état d'avertissement**. Ces moteurs présentent des signes de dégradation et doivent être surveillés afin de prévenir des pannes.
- **14 moteurs (14 %)** sont en **état de danger**. Ces moteurs nécessitent une intervention immédiate pour éviter des défaillances critiques.

Graphiques des cycles réalisés

- **Fonctionnement optimal :** Les moteurs en bon état montrent une stabilité sur le nombre de cycles réalisés, ce qui confirme leur fiabilité.

- **Surveiller les changements** : Les moteurs en avertissement présentent une augmentation progressive des cycles réalisés, ce qui indique une détérioration de leur état. Une planification proactive de la maintenance est nécessaire.
- **Maintenance immédiate** : Les moteurs en danger ont accumulé un nombre élevé de cycles, atteignant ou dépassant le seuil critique, et nécessitent des actions correctives immédiates.

Distribution des états (camembert)

La répartition visuelle des états montre qu'une majorité des moteurs est en bon état (59 %). Toutefois, avec 41 % des moteurs nécessitant une attention (**avertissement** ou **danger**), il est essentiel d'orienter les efforts vers une gestion proactive pour éviter les interruptions de service.

7.2 Vue Moteur : Analyse individuelle




FIGURE 7.2 – Deuxième page - Vue Moteur

La seconde page offre une analyse détaillée et ciblée sur un moteur spécifique, permettant une gestion fine de la maintenance.

Cycles réalisés et cycles restants estimés

- Le moteur analysé a effectué **192 cycles**.

- Il reste **81 cycles estimés** avant d’atteindre le seuil critique de défaillance. Cette estimation fournit une indication claire pour planifier une intervention de maintenance avant la panne.

Dégradation de l’indicateur de santé

Le graphique présente l’évolution de la santé du moteur (**indicateur observé en bleu** et **prédit en gris**) en fonction des cycles. Le **seuil de défaillance (ligne rouge)** est une référence critique. Le moteur montre une progression vers ce seuil, mais reste en bon état pour le moment. Cette visualisation permet de suivre la tendance de dégradation et de confirmer que le moteur reste exploitable pour un certain nombre de cycles avant intervention.

Comparaison avec des moteurs similaires

Le graphique à droite compare les performances de **5 moteurs similaires**. Bien que ce moteur soit en bon état par rapport à d’autres moteurs, les tendances globales de dégradation confirment une évolution prévisible vers un besoin de maintenance.

État global du moteur

Le moteur est actuellement classé en **bon état**, mais la surveillance continue reste essentielle pour anticiper sa maintenance à mesure qu’il approche du seuil critique.

7.3 Conclusion

Le tableau de bord de maintenance prédictive offre une **vision globale et détaillée** de l’état des moteurs turbo-fan, permettant une gestion **proactive et optimisée** des interventions. Avec **14 %** des moteurs en **danger** nécessitant une maintenance immédiate et **27 %** en **état d’avertissement**, il est essentiel de prioriser ces moteurs pour prévenir les pannes critiques. L’intégration des cycles réalisés, des cycles restants estimés, et des tendances de dégradation facilite une **planification précise**, réduisant les **coûts d’entretien** tout en garantissant la **disponibilité** et la **sécurité** des moteurs en opération.

Conclusion Générale

Dans un contexte industriel de plus en plus exigeant, où la sécurité, la disponibilité et la rentabilité sont des priorités, la maintenance prédictive s'impose comme une solution incontournable pour gérer les équipements critiques, tels que les moteurs turbo-fan. Ce projet met en avant l'importance des technologies modernes, comme l'intelligence artificielle et l'apprentissage automatique, pour révolutionner les pratiques de maintenance, en permettant de prédire les défaillances avant qu'elles ne surviennent et ainsi optimiser les opérations industrielles.

À travers le développement d'un tableau de bord interactif, cette étude a permis de créer un outil puissant pour la gestion proactive de la maintenance des moteurs turbo-fan. Ce tableau de bord offre une visualisation claire et dynamique des états des moteurs, en mettant en évidence les prédictions de la durée de vie restante (RUL) et en permettant un suivi détaillé des indicateurs de santé des moteurs. L'intégration de techniques d'analyse avancées, telles que les modèles statistiques et les approches de machine learning, améliore considérablement l'efficacité de la gestion de la maintenance.

L'utilisation de cet outil facilite une prise de décision plus éclairée, en identifiant les moteurs nécessitant une attention immédiate, comme ceux en état d'avertissement ou de danger, permettant ainsi de prévenir les pannes critiques et de réduire les coûts liés aux interventions d'urgence. En permettant une gestion plus ciblée des cycles de maintenance, ce tableau de bord contribue à augmenter la disponibilité et la fiabilité des équipements tout en réduisant les interruptions imprévues.

En conclusion, ce projet démontre l'énorme potentiel des technologies de maintenance prédictive pour améliorer les performances industrielles. Grâce à une approche méthodique et des outils d'analyse avancés, il offre une solution concrète pour anticiper les défaillances, optimiser la gestion des interventions, et assurer la durabilité et la performance des équipements critiques.

Références

1. Saxena, A., Goebel, K., Simon, D., & Eklund, N. (2008). *Damage Propagation Modeling for Aircraft Engine Run-to-Failure Simulation*. In Proceedings of the 1st International Conference on Prognostics and Health Management (PHM08), Denver, CO.
2. Baptista, M., Sankararaman, M., & Goebel, K. (2022). *Relation between Prognostics Predictor Evaluation Metrics and Local Interpretability SHAP Values*. *Artificial Intelligence*, 306, 103667. Disponible sur : <https://www.sciencedirect.com/science/article/pii/S0004370222000078>
3. Siret, L., Agard, B., Danjou, C., & Bonnard, R. (2019). *Prédictions de RUL par Analyse de Similarités*. Disponible sur : https://www.researchgate.net/publication/352980735_Predictions_de_RUL_par_Analyse_de_Similarites

Sites Web

- NASA. *C-MAPSS Jet Engine Simulated Data*. Disponible sur : https://data.nasa.gov/Aerospace/CMAPSS-Jet-Engine-Simulated-Data/ff5v-kuh6/about_data
- Tribofilm. *Les différents types de maintenance*. Disponible sur : <https://www.tribofilm.fr/les-differents-types-de-maintenance/>
- L'avionnaire. *Moteur à réaction*. Disponible sur : <https://www.lavionnaire.fr/MotorElements.php>
- Aeroaffaires. *Fonctionnement moteur à réaction*. Disponible sur : <https://aeroaffaires.fr/fonctionnement-moteur-a-reaction/>
- Bibmath. *Kolmogorov Test*. Disponible sur : <https://www.bibmath.net/dico/index.php?action=affiche&quoi=./k/kolmogorovtest.html>
- Bibmath. *Chi-Deux Test*. Disponible sur : <https://www.bibmath.net/dico/index.php?action=affiche&quoi=./c/chideuxtest.html>
- MathWorks. *Predict Remaining Useful Life*. Disponible sur : https://fr.mathworks.com/help/predmaint/predict-remaining-useful-life.html?s_tid=CRUX_lftnav
- MathWorks. *Three Ways to Estimate Remaining Useful Life for Predictive Maintenance*. Disponible sur : <https://www.mathworks.com/company/technical-articles/three-ways-to-estimate-remaining-useful-life-for-predictive-maintenance.html>
- MathWorks. *Wind Turbine High-Speed Bearing Prognosis*. Disponible sur : <https://fr.mathworks.com/help/predmaint/ug/wind-turbine-high-speed-bearing-prognosis.html>